

UNIVERSITÉ PARIS-EST-CRÉTEIL ESIPE
---------------------------------------

# Statistique descriptive et probabilités

Spécialité : L1

BÉATRICE DE TILIÈRE  
DAVID GODHINO

---



# TABLE DES MATIÈRES

<b>I</b>	<b>Statistique Descriptive</b>	<b>3</b>
<b>1</b>	<b>LES DONNÉES STATISTIQUES</b>	<b>5</b>
1.1	Un peu de vocabulaire . . . . .	5
1.2	Notations . . . . .	6
1.3	Deux directions en statistique . . . . .	7
1.3.1	Statistique descriptive . . . . .	8
1.3.2	Statistique inférentielle . . . . .	8
<b>2</b>	<b>TABLEAUX ET REPRÉSENTATIONS GRAPHIQUES</b>	<b>9</b>
2.1	Groupement des données . . . . .	9
2.2	Effectifs et fréquences . . . . .	10
2.2.1	Effectifs et fréquences . . . . .	10
2.2.2	Effectifs et fréquences cumulé(e)s . . . . .	11
2.2.3	Amplitude et densité de proportion . . . . .	12
2.3	Représentations graphiques . . . . .	13
2.3.1	Variables qualitatives . . . . .	14
2.3.2	Variables quantitatives discrètes . . . . .	16
2.3.3	Variables quantitatives continues . . . . .	17
2.4	Fonction de répartition empirique . . . . .	18
2.4.1	Variables quantitatives discrètes . . . . .	19
2.4.2	Variable quantitative continue . . . . .	19
<b>3</b>	<b>STATISTIQUE DESCRIPTIVE UNIVARIÉE</b>	<b>21</b>
3.1	Paramètres de position . . . . .	22
3.1.1	Le mode . . . . .	22
3.1.2	La moyenne (arithmétique) . . . . .	22
3.1.3	Médiane, quartiles, quantiles . . . . .	24
3.1.4	Réflexions sur le mode, la moyenne, et la médiane . . . . .	26
3.1.5	Moyennes géométrique, harmonique et quadratique . . . . .	26
3.2	Paramètres de dispersion . . . . .	27
3.2.1	Étendue et distance interquartile . . . . .	27
3.2.2	Variance et écart-type . . . . .	27
3.3	Box plot ou boîte à moustaches . . . . .	30
3.4	Paramètres de forme . . . . .	31
3.4.1	Variable centrée réduite . . . . .	31
3.4.2	Moments d'une distribution . . . . .	31
3.4.3	Coefficient d'asymétrie de Fisher . . . . .	32
3.4.4	Coefficient d'aplatissement . . . . .	32

---

3.5	Courbe de concentration de Lorenz et indice de Gini . . . . .	33
3.5.1	Courbe de concentration de Lorenz . . . . .	33
3.5.2	Indice de Gini . . . . .	36
<b>4</b>	<b>STATISTIQUE DESCRIPTIVE BI-VARIÉE</b>	<b>37</b>
4.1	Distributions marginales et conditionnelles . . . . .	38
4.2	Indépendance . . . . .	40
4.2.1	Définition . . . . .	40
4.2.2	Écart à l'indépendance . . . . .	41
4.3	Nuage de points, résumés numériques . . . . .	41
4.3.1	Nuage de points . . . . .	42
4.3.2	Moyenne, variance, écart-type . . . . .	42
4.3.3	Covariance . . . . .	43
4.3.4	Coefficient de corrélation . . . . .	45
4.4	Ajustement affine . . . . .	46
4.4.1	Méthode des moindres carrés . . . . .	46
4.4.2	Méthode de Mayer . . . . .	47
4.4.3	Un exemple . . . . .	48
<b>II</b>	<b>Probabilités</b>	<b>51</b>
<b>5</b>	<b>MODÉLISATION DES PHÉNOMÈNES ALÉATOIRES</b>	<b>53</b>
5.1	Introduction . . . . .	53
5.2	L'espace probabilisé $(\Omega, \mathcal{A}, \mathbb{P})$ . . . . .	54
5.2.1	Espace des états . . . . .	54
5.2.2	Événements . . . . .	55
5.2.3	Probabilité . . . . .	56
<b>6</b>	<b>CONSTRUCTION D'ESPACES PROBABILISÉS</b>	<b>59</b>
6.1	Caractérisation d'une probabilité . . . . .	59
6.2	Cas où l'univers est fini . . . . .	59
6.2.1	Dénombrement, modèle d'urne . . . . .	60
6.3	Espace des états infini dénombrable . . . . .	64
<b>7</b>	<b>CONDITIONNEMENT ET INDÉPENDANCE</b>	<b>65</b>
7.1	Probabilité conditionnelle . . . . .	65
7.1.1	Définition . . . . .	65
7.1.2	Formule des probabilités totales et formule de Bayes . . . . .	67
7.2	Indépendance des événements . . . . .	69

---

Première partie

Statistique Descriptive



# CHAPITRE 1

## LES DONNÉES STATISTIQUES

La *statistique*<sup>1</sup> est une méthode scientifique qui consiste à observer et à étudier une/plusieurs particularité(s) commune(s) chez un groupe de personnes ou de choses.

### 1.1 UN PEU DE VOCABULAIRE

**Définition 1.1.** La *population* est l'ensemble des éléments à étudier ayant des propriétés communes. Un *individu* est un élément de la population étudiée. La *taille* de la population est le nombre d'individus. Un *échantillon* est la partie étudiée de la population.

*Exemple.* Population : ensemble de parcelles sur lesquelles on mesure un rendement, un groupe d'insectes, élèves d'un groupe de TD, ensemble des accidents d'avion. Individu : une des parcelles, un des insectes, etc.

*Remarque.* La collecte de données (obtention de l'échantillon à partir de la population) est une étape clé et délicate. Nous ne traitons pas ici des méthodes possibles, mais attirons l'attention sur le fait que l'hypothèse sous-jacente est que l'échantillon d'individus étudiés est choisi "au hasard" parmi tous les individus qui auraient pu être choisis. Il faut tout mettre en œuvre pour que cette hypothèse soit satisfaite. Dans la suite, sauf mention explicite du contraire, nous considérons que l'étude statistique porte sur la population complète.

**Définition 1.2.** Une *variable* ou *caractère* est une propriété commune aux individus de la population, que l'on souhaite étudier. Elle peut être :

- *qualitative* : lorsque les valeurs prises par la variable ne sont pas une quantité mesurable par un nombre mais appartiennent à un groupe de catégories. On les appelle *modalités* de la variable. On distingue :
  - les variables qualitatives *nominales* : il n'y a pas de hiérarchie entre les différentes modalités ; exemple : sexe, couleur des yeux, couleur de pétales.
  - les variables qualitatives *ordinales* : les différentes modalités peuvent être ordonnées de manière naturelle ; exemple : la mention au baccalauréat, la fréquence d'une activité (jamais, rarement, parfois, souvent, très souvent).

*Remarque.* Certaines variables qualitatives peuvent être désignées par un code numérique, qui n'a pas de valeur de quantité. Exemple : le code postal, le sexe (1=garçon, 2=filles).

---

1. La statistique est à différencier d'"une statistique", qui est un nombre calculé à propos d'une population.



- *quantitative (numérique)* : lorsque les valeurs prises par la variable correspondent à des quantités mesurables et sont données par des nombres. On distingue :
  - les variables quantitatives *discrètes* : elles prennent leurs valeurs dans un ensemble discret, le plus souvent fini ; exemple : le nombre d'enfants, la pointure du pied, le nombre d'espèces recensées sur une parcelle.
  - les variables quantitatives *continues* : elles peuvent prendre toutes les valeurs d'un intervalle réel ; exemple : la taille des individus, le poids d'un individu, le périmètre d'une coquille de moule.

*Remarque.* L'âge peut être vu et traité comme une variable quantitative discrète ou continue suivant la précision que l'on choisit et le nombre de valeurs qu'il prend au sein de la population. Il peut également exister des variables basées sur l'âge qui sont qualitatives. Si dans un sondage on pose la question "quelle est votre tranche d'âge parmi les possibilités suivantes : - de 25 ans, entre 25 et 40, entre 40 et 60 et + de 60 ans", on peut voir la variable "tranche d'âge" comme une variable qualitative ordinale.

**Définition 1.3.** L'ensemble des données de la/les variable(s) s'appelle la *série statistique*. Si l'étude statistique porte sur un seul critère, on dit que la série statistique est *simple* (ou *univariée*). Si l'étude porte sur deux ou plusieurs critères, la série est dite respectivement *double* (ou *bivariée*) ou *multiple*.

*Exemple.* Étudier la longueur des pétales sur une population d'iris donne une série statistique simple ; étudier la longueur et la largeur des pétales donne une série statistique double.

## 1.2 NOTATIONS

Voici les terminologies et notations usuelles pour les définitions ci-dessus.

Terminologie	Notation
Taille de la population	$N$
Population <sup>2</sup>	$\mathcal{P} = \{1, \dots, N\}$
Individu	$u \in \mathcal{P}$
Variables	$X, Y, \dots$
Donnée de la variable $X$ pour l'individu $u$	$X(u)$
Série statistique (simple) <i>brute</i> pour $X$	$\{X(1), \dots, X(N)\}$
Série statistique (double) <i>brute</i> pour $X$ et $Y$	$\{(X(1), Y(1)), \dots, (X(N), Y(N))\}$

TABLE 1.1 – Notations

*Exemple 1.1* (Voitures propres). Une petite enquête s'intéresse au constructeur de voiture propre préféré de 11 individus. Les constructeurs proposés sont : Peugeot (P), Renault (R), Citroën (C), Nissan (N), Tesla (T) ; on a la statistique (simple) brute suivante.

Utilisateur	1	2	3	4	5	6	7	8	9	10	11
Constructeur préféré ( $X$ )	T	T	R	P	N	C	N	T	P	C	T

2. Il s'avère souvent pratique, voire incontournable (anonymat, etc.), de désigner les individus par des nombres.

La population  $\mathcal{P}$  est l'ensemble des 11 individus. La taille de la population est  $N = 11$ . Les individus sont désignés par des numéros. La variable  $X$  étudiée est “le constructeur de voiture propre préféré” ; il s'agit d'une variable qualitative nominale. On a par exemple,

$$X(1) = \text{Tesla}.$$

*Exemple 1.2* (Développeuse). Une développeuse d'applications récolte les avis des utilisateurs (de 0 à 5 étoiles). Elle obtient la statistique brute suivante.

Utilisateur	1	2	3	4	5	6	7	8	9	10
Nombre d'étoiles ( $X$ )	1	3	5	5	4	2	4	4	5	3

La population  $\mathcal{P}$  est l'ensemble des utilisateurs qui ont donné un avis. La taille de la population est  $N = 10$ . Les utilisateurs sont désignés par des numéros. La variable  $X$  étudiée est “l'avis donné” ; il s'agit d'une variable qualitative ordinale. On a par exemple,

$$X(4) = 5 \text{ étoiles}.$$

*Exemple 1.3* (Température juillet). On s'intéresse à la température moyenne au mois de juillet dans plusieurs villes de France. On obtient la série statistique brute suivante.

Ville	Température moyenne en juillet ( $X$ )
Ajaccio	22.2
Bordeaux	20.8
Clermont-Ferrand	19.7
Brest	16.6
Lille	17.9
Lyon	21.3
Millau	19.3
Nice	23.1
Paris	20
Strasbourg	19.5
Toulouse	21.6
Fort-de-France	27.5
Papeete	25

La population  $\mathcal{P}$  est l'ensemble des villes de France considérées. La taille de la population est  $N = 12$ . Dans ce cas, les individus (les villes) ne sont pas désignés par des nombres, mais par leur nom. La variable  $X$  étudiée est “la température moyenne au mois de juillet” ; il s'agit d'une variable quantitative continue. On a par exemple,

$$X(\text{Bordeaux}) = 20,8^\circ.$$

### 1.3 DEUX DIRECTIONS EN STATISTIQUE

Il y a deux grandes manières de faire de la statistique : soit descriptive (le sujet de ce cours), soit inférentielle. Nous présentons brièvement les deux approches.

### 1.3.1 STATISTIQUE DESCRIPTIVE

La statistique descriptive a pour but de décrire, c'est-à-dire de résumer ou représenter, par des statistiques, les données disponibles quand elles sont nombreuses. Quelques questions typiques :

1. Représentation graphique.
2. Paramètres de position, de dispersion, de relation.
3. Régression linéaire.
4. Questions liées à des grands jeux de données (non traité dans ce cours).

### 1.3.2 STATISTIQUE INFÉRENTIELLE

En statistique inférentielle les données ne sont pas considérées comme une information complète, mais une information partielle d'une population infinie. Il est alors naturel de supposer que les données sont des réalisations de variables aléatoires, qui ont une certaine loi de probabilité.

Cette approche nécessite des outils mathématiques plus pointus de théorie des probabilités.

Quelques questions typiques :

1. Estimation de paramètres.
2. Intervalles de confiance.
3. Tests d'hypothèse.
4. Modélisation : exemple (régression linéaire).

La statistique inférentielle n'est pas traitée dans ce cours.

# CHAPITRE 2

## TABLEAUX ET REPRÉSENTATIONS GRAPHIQUES

### 2.1 GROUPEMENT DES DONNÉES

Dans le chapitre précédent nous avons vu des exemples de séries statistiques simples dont les données sont écrites sous forme brute :  $\{X(1), \dots, X(N)\}$ . Dans la pratique, le nombre d'individus étant typiquement très grand, il faut réorganiser ces données en les regroupant. La première étape consiste,

- pour une variable qualitative ou quantitative discrète : à identifier les modalités/valeurs prises par la variable, c'est-à-dire à identifier  $X(\mathcal{P})$  ;
- pour une variable quantitative continue : à construire des intervalles ou *classes* formant une partition de l'ensemble des valeurs possibles de la variable. Si possible, on fait en sorte que les classes soient d'amplitude égale, au nombre de 5 à 20 (de préférence entre 6 et 12), contiennent leur borne inférieure mais pas leur borne supérieure (sauf la dernière).

*Remarque.* Lorsque une variable quantitative discrète prend un grand nombre de valeurs différentes, il est souvent utile de la voir comme une variable quantitative continue et d'effectuer un regroupement en classes. Cela permet une analyse plus claire des données.

Voici les notations utilisées dans ce cours. À noter que dans le tableau ci-dessous on a toujours  $p \leq N$ .

Terminologie	Notation
Nombre de modalités/valeurs/intervalles pour $X$	$p$
Modalités de $X$ , variable qualitative	$X(\mathcal{P}) = \{m_1, \dots, m_p\}$
Valeurs prises par $X$ , variable quantitative discrète	$X(\mathcal{P}) = \{x_1, \dots, x_p\}$
Intervalles pour $X$ , variable quantitative continue	$\{[a_0, a_1[, \dots, [a_{p-1}, a_p]\}$

TABLE 2.1 – Notations

*Exemple.* Reprenons les exemples 1.1, 1.2 et 1.3 de la section 1.2.

- *Voitures propres.* On a  $p = 5$ , et les modalités possibles sont,  $m_1 = P, m_2 = R, m_3 = C, m_4 = N, m_5 = T$ , autrement dit  $X(\mathcal{P}) = \{P, R, C, N, T\}$ .
- *Développeuse.* On a  $p = 6$ , et les modalités possibles sont,  $m_1 = 0, \dots, m_6 = 5$ , autrement dit  $X(\mathcal{P}) = \{0, \dots, 5\}$ .

- *Température juillet*. La variable étant continue il faut construire des classes. Une solution est de prendre  $p = 6$ , avec les intervalles :

$$[16, 18[, [18, 20[, [20, 22[, [22, 24[, [24, 26[, [26, 28[.$$

## 2.2 EFFECTIFS ET FRÉQUENCES

Afin de retrouver toutes l'information de la série statistique brute en utilisant les regroupements de la section précédente, il faut donner pour chacune des modalités/valeurs/classes son *effectif*. Ceci nous permet ensuite de définir les *fréquences* et *fréquences cumulées*.

Dans toute cette section, nous considérons une population  $\mathcal{P}$  de taille  $N$  pour laquelle nous étudions une variable  $X$ .

### 2.2.1 EFFECTIFS ET FRÉQUENCES

Rappelons que les modalités/valeurs/classes de la variable  $X$  sont notées  $m_1, \dots, m_p / x_1, \dots, x_p / [a_0, a_1[, \dots, [a_{p-1}, a_p[$ .

**Définition 2.1.** Soit  $i \in \{1, \dots, p\}$ .

1. Le nombre  $n_i$  d'individus pour lesquels la modalité/valeur de la variable  $X$  est  $m_i/x_i$  dans  $[a_{i-1}, a_i[$ , est appelé *l'effectif* ou la *fréquence absolue* associé à la modalité/valeur/classe  $m_i/x_i/[a_{i-1}, a_i[$  :

$$n_i = \text{card}\{u \in \mathcal{P} \mid X(u) = m_i / X(u) = x_i / X(u) \in [a_{i-1}, a_i[ \}.$$

2. La *fréquence relative* ou simplement *fréquence* associée à la modalité/valeur/classe  $m_i/x_i/[a_{i-1}, a_i[$ , notée  $f_i$ , est le quotient de son effectif par la taille de la population :

$$f_i = \frac{n_i}{N}.$$

*Remarque.* Pour une variable qualitative ou quantitative discrète, il est équivalent de se donner la série statistique sous forme brute ou sous forme groupée avec les effectifs :

$$\begin{aligned} \text{Variable qualitative : } \{X(1), \dots, X(N)\} &\Leftrightarrow \{(m_1, n_1), \dots, (m_p, n_p)\} \\ \text{Variable quantitative discrète : } \{X(1), \dots, X(N)\} &\Leftrightarrow \{(x_1, n_1), \dots, (x_p, n_p)\}. \end{aligned}$$

Pour une variable quantitative continue, on perd de l'information en regroupant les données car on ne connaît plus la répartition à l'intérieur des classes.

*Exemple.* Reprenons les exemples de la section 1.2.

- *Voitures propres*. Les effectifs des modalités sont :  $n_1 = 2, n_2 = 1, n_3 = 2, n_4 = 2, n_5 = 4$ .
- *Développeuse*. Les effectifs des modalités sont :  $n_1 = 0, \dots, n_6 = 2$ .
- *Température juillet*. Les effectifs des classes sont :  $n_1 = 2, \dots, n_6 = 1$ .

**Propriété 2.1.**

$$\sum_{i=1}^p n_i = N, \quad \sum_{i=1}^p f_i = 1 \quad \text{et} \quad \forall i \in \{1 \dots p\}, 0 \leq f_i \leq 1.$$

*Démonstration.* La première somme est une autre manière de calculer le nombre total d'individus, soit  $N$ . On utilise ensuite la définition de la fréquence pour obtenir

$$\sum_{i=1}^p f_i = \sum_{i=1}^p \frac{n_i}{N} = \frac{1}{N} \sum_{i=1}^p n_i = \frac{N}{N} = 1.$$

L'encadrement de  $f_i$  vient du fait que  $0 \leq n_i \leq N$ . □

A l'aide de ces quantités, on peut construire un tableau qui permet de résumer les données.

Variable $X$	$m_1/x_1/[a_0, a_1[$	$m_2/x_2/[a_1, a_2[$	$\dots$	$m_p/x_p/[a_{p-1}, a_p]$	Total
Effectif ou fréquence absolue	$n_1$	$n_2$	$\dots$	$n_p$	$N$
Fréquence ou fréquence relative	$f_1 = \frac{n_1}{N}$	$f_2 = \frac{n_2}{N}$	$\dots$	$f_p = \frac{n_p}{N}$	1

*Exemple 2.1* (Pratiques sportives). On étudie la répartition des 9379079 français exerçant une pratique sportive en 2013. Les données sont les suivantes :

Discipline	Aviron	Basket-ball	Cyclisme	Football	Tennis	Autre
Nombre de licenciés	103084	536891	119247	2002398	1111316	5506143

La population  $\mathcal{P}$  est l'ensemble des personnes exerçant une activité sportive dans un club en France en 2013. La taille de la population est  $N = 9379079$ . La variable  $X$  est la discipline du sport choisi. Il s'agit d'une variable qualitative nominale dont les modalités sont : aviron, basket-ball, cyclisme, football, tennis et autre.

Pour déterminer la fréquence d'une modalité, il suffit de diviser l'effectif de cette dernière par la taille  $N$  de la population. On obtient pour l'aviron par exemple une fréquence égale à  $\frac{103084}{9379079} = 0.0109908$ . On arrondit ensuite le résultat à quatre chiffres après la virgule afin d'avoir une précision de deux chiffres après la virgule si on exprime le résultat en pourcentage. On obtient le tableau suivant :

Variable $X$	Aviron	Basket-ball	Cyclisme	Football	Tennis	Autre	Total
Effectif	103084	536891	119247	2002398	1111316	5506143	9379079
Fréquence	0.0110	0.0572	0.0127	0.2135	0.1185	0.5871	1

### 2.2.2 EFFECTIFS ET FRÉQUENCES CUMULÉ(E)S

Dans cette section, on exclut le cas des *variables qualitatives nominales*. Si la variable  $X$  est qualitative ordinale, on suppose que les modalités  $m_1, \dots, m_p$  sont ordonnées suivant l'ordre croissant naturel (ou hiérarchique ascendant) ; si elle est quantitative discrète, on suppose que les valeurs sont classées en ordre croissant :  $x_1 < \dots < x_p$  ; si elle est quantitative continue, on a un ordre naturel sur les intervalles :  $[a_0, a_1[, \dots, [a_{p-1}, a_p]$ .

**Définition 2.2.** Soit  $i \in \{1, \dots, p\}$ .

1. L'*effectif cumulé croissant* (respectivement *effectif cumulé décroissant*) jusqu'à la modalité/valeur/classe  $m_i/x_i/[a_{i-1}, a_i[$ , noté  $\nu_i$  (respectivement  $\tilde{\nu}_i$ ), est la somme des effectifs  $n_1, \dots, n_i$  (respectivement  $n_i, \dots, n_p$ ) :

$$\nu_i = \sum_{j=1}^i n_j \quad \text{et} \quad \tilde{\nu}_i = \sum_{j=i}^p n_j.$$

2. La *fréquence cumulée croissante* (respectivement *fréquence cumulée décroissante*) jusqu'à la modalité/valeur/classe  $m_i/x_i/[a_{i-1}, a_i[$ , notée  $\phi_i$  (respectivement  $\tilde{\phi}_i$ ), est la somme des fréquences  $f_1, \dots, f_i$  (respectivement  $f_i, \dots, f_p$ ) :

$$\phi_i = \sum_{j=1}^i f_j \quad \text{et} \quad \tilde{\phi}_i = \sum_{j=i}^p f_j.$$

On obtient alors le tableau complété suivant.

Variable $X$	$m_1/x_1/[a_0, a_1[$	$m_2/x_2/[a_1, a_2[$	$\dots$	$m_p/x_p/[a_{p-1}, a_p]$	Total
Effectif	$n_1$	$n_2$	$\dots$	$n_p$	$N$
Fréquence	$f_1 = \frac{n_1}{N}$	$f_2 = \frac{n_2}{N}$	$\dots$	$f_p = \frac{n_p}{N}$	1
Fréquence cum. crois.	$\phi_1 = f_1$	$\phi_2 = f_1 + f_2$	$\dots$	$\phi_p = 1$	pas de sens
Fréquence cum. décrois.	$\tilde{\phi}_1 = 1$	$\tilde{\phi}_2 = f_2 + \dots + f_p$	$\dots$	$\tilde{\phi}_p = f_p$	pas de sens

*Exemple 2.2* (Ordinateurs). Un responsable du service marketing d'une grande marque d'ordinateurs (portables et de bureau) fait une enquête dans une université pour savoir combien d'ordinateurs (portables ou de bureau) il y a dans le foyer de chaque étudiant. Les données sont les suivantes.

Nombre d'ordinateurs	0	1	2	3	4	5	Total
Nombre d'étudiants	300	876	1235	984	225	154	3774

La population  $\mathcal{P}$  est l'ensemble des étudiants de l'université. La taille de la population est  $N = 3774$ . La variable  $X$  est le nombre d'ordinateurs ; il s'agit d'une variable quantitative discrète. On obtient le tableau suivant :

Nombre d'ordinateurs	0	1	2	3	4	5	Total
Effectif	300	876	1235	984	225	154	3774
Fréquence	0.0795	0.2321	0.3272	0.2607	0.0596	0.0408	1
Fréquence cumulée croissante	0.0795	0.3116	0.6388	0.8996	0.9592	1	pas de sens
Fréquence cumulée décroissante	1	0.9205	0.6884	0.3612	0.1004	0.0408	pas de sens

### 2.2.3 AMPLITUDE ET DENSITÉ DE PROPORTION

Dans cette section on se restreint au cas où la variable  $X$  est *quantitative continue*, avec classes  $[a_0, a_1[, \dots, [a_{p-1}, a_p]$ . On a alors la définition supplémentaire suivante.

**Définition 2.3.** Soit  $i \in \{1, \dots, p\}$ .

1. L'amplitude de la classe  $[a_{i-1}; a_i[$  est  $l_i := a_i - a_{i-1}$ .
2. La densité de proportion de la classe  $[a_{i-1}; a_i[$  est  $d_i := f_i/l_i$ .

*Remarque.*

1. La densité de proportion permet de comparer les effectifs dans chaque classe en tenant compte de la taille de ces classes (cf. la notion de densité de population en géographie).
2. Dans le cas de classes qui ont toutes la même longueur, il n'est pas nécessaire de calculer la densité de proportion, il est suffisant d'étudier les fréquences relatives ou absolues (qui sont directement proportionnelles à la densité de proportion).

On obtient alors le tableau complété suivant.

Variable $X$	$[a_0, a_1[$	$[a_1, a_2[$	$\dots$	$[a_{p-1}, a_p]$	Total
Effectif	$n_1$	$n_2$	$\dots$	$n_p$	$N$
Fréquence	$f_1 = \frac{n_1}{N}$	$f_2 = \frac{n_2}{N}$	$\dots$	$f_p = \frac{n_p}{N}$	1
Fréquence cumulée crois.	$\phi_1 = f_1$	$\phi_2 = f_1 + f_2$	$\dots$	$\phi_p = 1$	pas de sens
Fréquence cumulée décrois.	$\tilde{\phi}_1 = 1$	$\tilde{\phi}_2 = f_2 + \dots + f_p$	$\dots$	$\tilde{\phi}_p = f_p$	pas de sens
Amplitude	$l_1 = a_1 - a_0$	$l_2 = a_2 - a_1$	$\dots$	$l_p = a_p - a_{p-1}$	pas de sens
Densité de proportion	$d_1 = f_1/l_1$	$d_2 = f_2/l_2$	$\dots$	$d_p = f_p/l_p$	pas de sens

*Exemple 2.3* (Moyennes CC). Un professeur obtient les moyennes de contrôle continu suivantes : 8.25, 14.25, 9.5, 14, 6.25, 11.75, 10, 10, 17, 14.75, 8, 6, 12.75, 10, 18.75, 11.5, 11.25, 19.25, 3, 13.5, 12.25, 13, 18.5, 15, 17, 10, 6, 12.25, 4.75, 16, 10.75, 9.75, 15.5, 12, 16.5, 15.25.

La population  $\mathcal{P}$  est l'ensemble des étudiants du groupe de TD. La taille de la population est  $N = 36$ . La variable  $X$  est la moyenne de CC ; il s'agit d'une variable quantitative discrète, mais vu que le nombre de valeurs différentes est grand, on va effectuer une répartition en cinq classes d'amplitude 4. L'amplitude étant constante, on n'a pas besoin de calculer la densité de proportion. On obtient le tableau suivant.

Moyenne CC	$[0, 4[$	$[4, 8[$	$[8, 12[$	$[12, 16[$	$[16, 20]$	Total
Effectif	1	4	12	12	7	36
Fréquence	0.0278	0.1111	0.3333	0.3333	0.1944	1
Fréquence cumulée croissante	0.0278	0.1389	0.4722	0.8056	1	pas de sens
Fréquence cumulée décroissante	1.0000	0.9722	0.8611	0.5278	0.1944	pas de sens

## 2.3 REPRÉSENTATIONS GRAPHIQUES

Pour chaque type de variables, il existe des représentations graphiques qui illustrent les tableaux obtenus dans la section précédente et permettent une bonne lecture des données.



### 2.3.1 VARIABLES QUALITATIVES


DIAGRAMMES À BANDES. Pour obtenir un diagramme à bandes, on trace un repère formé d'un axe horizontal non gradué et d'un axe vertical gradué.

- Sur l'axe horizontal, on trace des rectangles de même largeur, représentant les modalités, que l'on place à des distances régulières les uns des autres
- Les hauteurs des rectangles sont proportionnelles aux effectifs ou aux fréquences des modalités.

Reprenons les données de l'exemple 2.1 (pratiques sportives).

Discipline	Aviron	Basket-ball	Cyclisme	Football	Tennis	Autre
Nombre de licenciés	103084	536891	119247	2002398	1111316	5506143

On obtient le diagramme à bandes suivant.



*Remarque.*



1. Étant donné que les modalités sont qualitatives, il n'y a pas d'ordre entre elles.
2. Ce type de graphique permet aussi de comparer les résultats sur différentes années ou différentes populations.

On possède également les données de la répartition des pratiques sportives en France en 2012 :

Année	Aviron	Basket-ball	Cyclisme	Football	Tennis	Autre
2013	103084	536891	119247	2002398	1111316	5506143
2012	43788	475465	115891	1973260	1103519	5369765

On peut aussi donner une représentation de sous-populations. Toujours avec le même exemple, on considère que la répartition entre hommes et femmes est la suivante :

Sexe	Aviron	Basket-ball	Cyclisme	Football	Tennis	Autre
Homme	80810	230532	65312	1912023	629311	2538924
Femme	22274	306359	53935	90375	482005	2967219



DIAGRAMMES CIRCULAIRES. Dans le cas d'un diagramme *circulaire* (ou *camembert*), les modalités sont représentées par un secteur angulaire d'un disque (ou d'un demi-disque), dont l'angle est proportionnel à l'effectif ou à la fréquence. On effectue donc un produit en croix pour connaître l'angle de chaque secteur. Dans le cas d'un disque complet, on a ainsi les correspondances suivantes :

$$100\% \longleftrightarrow 360$$


$$x\% \longleftrightarrow \frac{x \times 360}{100} = x \times 3.6^\circ,$$

et dans le cas d'un demi-disque, on a :

$$100\% \longleftrightarrow 180^\circ$$

$$x\% \longleftrightarrow \frac{x \times 180}{100} = x \times 1.8^\circ.$$

Avec l'exemple des pratiques sportives, on obtient :




### 2.3.2 VARIABLES QUANTITATIVES DISCRÈTES

DIAGRAMME EN BÂTONS. Pour obtenir un diagramme en bâtons, on trace un repère formé de deux axes gradués orthogonaux.

- Sur l'axe des abscisses, on place les valeurs  $x_1, \dots, x_p$  prises par la variable.
- Sur l'axe des ordonnées, on place les effectifs ou les fréquences correspondant aux différentes valeurs.


Avec les données de l'exemple 2.2 (ordinateurs), on obtient :



*Remarque.* Le logiciel Excel ne permet pas vraiment de faire des diagrammes en bâtons. Il faut donc faire un histogramme et réduire au maximum la largeur des tubes.

**Définition 2.4.** La courbe joignant les sommets des bâtons est appelée *polygone des effectifs*, si l'on a représenté les effectifs, ou *polygone des fréquences*, si l'on a représenté les fréquences.

Avec les données de l'exemple 2.2, on obtient :



### 2.3.3 VARIABLES QUANTITATIVES CONTINUES

**HISTOGRAMME.** Pour obtenir un histogramme, on trace un repère formé de deux axes gradués orthogonaux.

- Sur l'axe des abscisses, on place les valeurs des bornes des classes,
- Sur l'axe des ordonnées, on place des pourcentages. Une classe  $[a_{i-1}; a_i[$  est représentée par un rectangle de largeur l'amplitude  $l_i$  et de hauteur la densité de proportion  $d_i$ . Cela revient en fait à ce que l'aire de ce rectangle soit la fréquence  $f_i$ . En effet, l'aire du rectangle représentant  $[a_{i-1}; a_i[$  est :

$$l_i d_i = l_i \frac{f_i}{l_i} = f_i.$$

Voici deux histogrammes pour l'exemple 2.3 (moyennes CC), pour des largeurs de classes différentes. Dans les deux cas, l'aire totale est égale à 1.

$X$	$[0, 4[$	$[4, 8[$	$[8, 12[$	$[12, 16[$	$[16, 20]$	Total
Fréquence relative	0.0278	0.1111	0.3333	0.3333	0.1944	1
Densité de proportion	0.0069	0.0278	0.0833	0.0833	0.0486	0.25

$X$	$[0, 8[$	$[8, 12[$	$[12, 16[$	$[16, 20]$	Total
Fréquence relative	0.1389	0.3333	0.3333	0.1944	1
Densité de proportion	0.0174	0.0833	0.0833	0.0486	0.25

*Remarque.*

1. Il n'est pas possible d'avoir une classe non bornée dans cette représentation car alors l'amplitude est  $+\infty$  et la densité de proportion 0. Si une classe est ouverte, il faut *introduire* « artificiellement » des bornes finies.





FIGURE 2.1 – Histogrammes de l'exemple 2.3 avec deux répartitions en classes différentes.

2. Ce qui compte dans l'histogramme est que l'aire d'une barre soit proportionnelle à l'effectif (ou la fréquence) de la classe. Ainsi, si l'amplitude des classes est constante, on peut mettre en ordonnée les effectifs ou les fréquences.
3. Avec un tableur, il ne semble pas possible de tracer un histogramme convenable lorsque l'amplitude n'est pas la même pour toutes les classes. De ce fait, lorsque nous ferons des représentations graphiques avec Excel, nous traiterons des cas où les amplitudes sont constantes.

Voici un histogramme fait avec Excel pour les effectifs des moyennes de contrôle continu, lorsque l'amplitude des classes est constante.



## 2.4 FONCTION DE RÉPARTITION EMPIRIQUE

Dans ce section, nous nous restreignons au cas des variables quantitatives. La fonction de répartition empirique permet de décrire la série statistique de manière complète. La définition diffère légèrement dans le cas discret et continu.

### 2.4.1 VARIABLES QUANTITATIVES DISCRÈTES

On suppose que la variable  $X$  est discrète et prend comme valeurs  $x_1 < \dots < x_p$ .

**Définition 2.5.** La *fonction de répartition empirique* de  $X$  est l'application  $F_X : \mathbb{R} \rightarrow [0, 1]$  construite comme suit :

- $\forall x \in ]-\infty, x_1[, F_X(x) = 0$ ;
- $\forall i \in \{1, \dots, p-1\}, \forall x \in [x_i, x_{i+1}[, F_X(x) = \phi_i$ ;
- $\forall x \in [x_p, +\infty[, F_X(x) = 1$ .

*Remarque.* La fonction  $F_X$  est une fonction càdlàg (continue à droite avec limite à gauche).

La fonction de répartition empirique de l'exemple 2.2 (ordinateurs) est donnée ci-dessous.




FIGURE 2.2 – Fonction de répartition empirique de l'exemple 2.2.

### 2.4.2 VARIABLE QUANTITATIVE CONTINUE

On suppose que la variable  $X$  est quantitative continue et a pour classes  $[a_0, a_1[, \dots, [a_{p-1}, a_p]$ .

**Définition 2.6.** La *fonction de répartition empirique* de  $X$  est l'application  $F_X : \mathbb{R} \rightarrow [0, 1]$  construite comme suit :

- $\forall x \in ]-\infty, a_0[, F_X(x) = 0$ ;
- $\forall i \in \{1, \dots, p\}, \forall x \in [a_{i-1}, a_i[, F_X(x) = \phi_{i-1} + d_i(x - a_{i-1})$ ;
- $\forall x \in [a_p, +\infty[, F_X(x) = 1$ .

La fonction de répartition empirique de l'exemple 2.3 (moyennes CC) est donnée ci-dessous.




FIGURE 2.3 – Fonction de répartition empirique de l'exemple 2.3.

*Remarque.*

1.  $F_X$  est définie sur  $\mathbb{R}$ , affine par morceaux et croissante.
2. Pour tout  $i \in \{1, \dots, p\}$ , on a :

$$\phi_i = F_X(a_i) \quad \text{et} \quad d_i = \frac{F_X(a_i) - F_X(a_{i-1})}{a_i - a_{i-1}}. \quad (2.1)$$

**Proposition 2.1.** *L'application  $F_X$  est continue sur  $\mathbb{R}$ .*

*Démonstration.* L'application  $F_X$  est affine par morceaux donc continue par morceaux. Les seuls éventuels points de discontinuité de  $F_X$  sont donc les points  $a_0, \dots, a_p$  de la subdivision – qui sont également les bornes des classes.

En  $a_0$ , on a :

$$\lim_{x \rightarrow a_0^-} F_X(x) = \lim_{x \rightarrow a_0^-} 0 = 0 \quad \text{et} \quad \lim_{x \rightarrow a_0^+} F_X(x) = \lim_{x \rightarrow a_0^+} (\phi_0 + d_1(x - a_0)) = \phi_0 = 0,$$

donc  $F_X$  est continue en  $a_0$ .

De même, en  $a_p$ , on a :

$$\begin{aligned} \lim_{x \rightarrow a_p^-} F_X(x) &= \lim_{x \rightarrow a_p^-} (\phi_{p-1} + d_p(x - a_{p-1})) = \phi_{p-1} + d_p(a_p - a_{p-1}) = \phi_p = 1 \\ \text{et} \quad \lim_{x \rightarrow a_p^+} F_X(x) &= \lim_{x \rightarrow a_p^+} 1 = 1, \end{aligned}$$

donc  $F_X$  est continue en  $a_p$ .

Enfin, fixons  $i \in \{1, \dots, p-1\}$ . En  $a_i$ , on a :

$$\begin{aligned} \lim_{x \rightarrow a_i^-} F_X(x) &= \lim_{x \rightarrow a_i^-} (\phi_{i-1} + d_i(x - a_{i-1})) = \phi_{i-1} + d_i(a_i - a_{i-1}) = \phi_i \\ \text{et} \quad \lim_{x \rightarrow a_i^+} F_X(x) &= \lim_{x \rightarrow a_i^+} (\phi_i + d_{i+1}(x - a_i)) = \phi_i, \end{aligned}$$

donc  $F_X$  est continue en  $a_i$ . □

# CHAPITRE 3

## STATISTIQUE DESCRIPTIVE UNIVARIÉE

Considérons une population  $\mathcal{P}$  de taille  $N$ ,  $\mathcal{P} = \{1, \dots, N\}$ , sur laquelle on étudie *une* variable  $X$ . Nous nous restreignons dans ce chapitre au cas des variables *quantitative*.

Nous disposons donc d'*une série statistique univariée* à laquelle nous souhaitons associer des paramètres qui synthétisent (réduisent) l'information. Ils sont essentiellement de trois types :

- les paramètres de position,
- les paramètres de dispersion,
- les paramètres de forme.

Rappelons les notations introduites pour la série statistique.

- Les individus sont numérotés de sorte à ce que les valeurs de la variable  $X$  soient croissantes. On a alors, la série sous forme brute :

$$X(1) \leq \dots \leq X(N).$$

- Si la variable  $X$  est *quantitative discrète*, on regroupe la série selon les valeurs prises par  $X$  en ordre croissant :

$$x_1 < \dots < x_p.$$

- Si la variable  $X$  est *quantitative continue*, on regroupe la série selon les classes de  $X$ , naturellement ordonnées :

$$[a_0, a_1[, \dots, [a_{p-1}, a_p].$$

Pour  $i \in \{1, \dots, p\}$ , on note  $x_i = \frac{a_{i-1} + a_i}{2}$  le centre de la classe  $[a_{i-1}, a_i[$ . Rappelons que lors du regroupement en classes, on perd l'information de la répartition à l'intérieure des classes. Dans les calculs de paramètres ci-dessous, on approchera les valeurs de la classes par son centre, et on obtiendra donc des paramètres *approchés* pour les variables continues.

Les exemples que nous donnons dans ce chapitre reprennent les données de l'exemple 2.2 (ordinateurs) pour le cas des variables discrètes. Pour rappel, nous avons obtenu le tableau suivant :

Nombre d'ordinateurs	0	1	2	3	4	5	Total
Effectif	300	876	1235	984	225	154	3774
Fréquence	0.0795	0.2321	0.3272	0.2607	0.0596	0.0408	1
Fréquence cumulée croissante	0.0795	0.3116	0.6388	0.8996	0.9592	1	pas de sens
Fréquence cumulée décroissante	1	0.9205	0.6884	0.3612	0.1004	0.0408	pas de sens



Dans le cas des variables continues, nous utilisons les données de l'exemple 2.3 (moyennes CC) :

Moyenne CC	[0, 4[	[4, 8[	[8, 12[	[12, 16[	[16, 20]	Total
Effectif	1	4	12	12	7	36
Fréquence	0.0278	0.1111	0.3333	0.3333	0.1944	1
Fréquence cumulée croissante	0.0278	0.1389	0.4722	0.8056	1	pas de sens
Fréquence cumulée décroissante	1	0.9722	0.8611	0.5278	0.1944	pas de sens

### 3.1 PARAMÈTRES DE POSITION

#### 3.1.1 LE MODE

Le mode contient l'information des valeurs où les données sont les plus “concentrées”.

##### Définition 3.1.

- Si la variable  $X$  est discrète, son *mode* est la ou les valeurs de la variable correspondant à la fréquence maximale.
- Si la variable  $X$  est continue, sa *classe modale*, est la ou les classes de densité de proportion maximale.

*Exemple.*

- *Ordinateurs.* Le mode est égal à 2.
- *Moyennes CC.* Il y a deux classes modales qui sont les classes  $[8, 12[$  et  $[12, 16[$ .

*Remarque.* Si  $X$  est discrète, une valeur de fréquence maximale est une valeur d'effectif maximal. Cette correspondance *n'a pas lieu* si  $X$  est continue car la densité de proportion tient compte de l'amplitude de la classe.

#### 3.1.2 LA MOYENNE (ARITHMÉTIQUE)

La moyenne arithmétique représente le *barycentre* de la série statistique, autour de laquelle sont ensuite calculés les paramètres de dispersion.

##### Définition 3.2.

- Si  $X$  est discrète, la *moyenne arithmétique*, notée  $\bar{x}$ , est la somme des valeurs pondérée par les fréquences :

$$\bar{x} = \sum_{i=1}^p f_i x_i = \frac{1}{N} \sum_{i=1}^p n_i x_i.$$

À partir des données brutes, la moyenne arithmétique est le quotient de la somme des valeurs associées à chaque individu par la taille de la population :

$$\bar{x} = \frac{1}{N} \sum_{u=1}^N X(u).$$

- Si  $X$  est continue, a priori, on ne peut faire qu'un encadrement de la moyenne arithmétique. Cependant, afin de pouvoir calculer un nombre, on appellera *moyenne arithmétique*  $\bar{x}$ , l'approximation de la moyenne obtenue en prenant comme valeurs les centres des classes :

$$\bar{x} = \sum_{i=1}^p f_i x_i = \frac{1}{N} \sum_{i=1}^p n_i x_i.$$

*Remarque.* La moyenne arithmétique a une unité : celle des valeurs de  $X$ .

*Exemple.*

- *Ordinateurs.* Pour la moyenne arithmétique, on obtient :

$$\bar{x} = \frac{1}{3774} (300 \times 0 + 876 \times 1 + 1235 \times 2 + 984 \times 3 + 225 \times 4 + 154 \times 5) = 2.11,$$

ou de manière équivalente :

$$\bar{x} = (0.08 \times 0 + 0.23 \times 1 + 0.33 \times 2 + 0.26 \times 3 + 0.06 \times 4 + 0.04 \times 5) = 2.11.$$

- *Moyennes CC.* La variable étant continue, il faut considérer les centres des classes pour obtenir :

$$\bar{x} = \frac{1}{36} (2 \times 1 + 6 \times 4 + 10 \times 12 + 14 \times 12 + 18 \times 7) = 12.22,$$

ou de manière équivalente :

$$\bar{x} = (2 \times 0.0278 + 6 \times 0.1111 + 10 \times 0.3333 + 14 \times 0.3333 + 18 \times 0.1944) = 12.22,$$

La moyenne possède une propriété intéressante vis-à-vis des changements de variables affines. Précisément :

**Proposition 3.1.** Soient  $a, b \in \mathbb{R}$  et  $Y$  la variable définie par  $Y = aX + b$ . La moyenne  $\bar{y}$  de  $Y$  satisfait à l'égalité suivante :

$$\bar{y} = a\bar{x} + b.$$

*Démonstration.* Si  $X$  est discrète (respectivement continue), alors  $Y$  est discrète (respectivement continue) et ses valeurs (respectivement centres des classes)  $y_1, \dots, y_p$  vérifient :

$$\forall i \in \{1, \dots, p\}, y_i = ax_i + b.$$

Donc la fréquence de la valeur (respectivement classe de centre)  $y_i$  est exactement celle de la valeur (respectivement classe de centre)  $x_i$ . Ainsi :

$$\bar{y} = \sum_{i=1}^p f_i y_i = \sum_{i=1}^p f_i (ax_i + b) = a \left( \sum_{i=1}^p f_i x_i \right) + b = a\bar{x} + b,$$

comme souhaité. □

### 3.1.3 MÉDIANE, QUARTILES, QUANTILES

**Définition 3.3.** Supposons que la variable  $X$  soit discrète. La *médiane*  $m$  est un nombre tel qu’au moins la moitié de l’effectif de la série soit inférieur ou égal à  $m$  et au moins la moitié de l’effectif de la série soit supérieur ou égal à  $m$ .

- si  $N$  est impair,  $N = 2P + 1$ , la série sous forme brute classée est :

$$X(1) \leq \dots \leq X(P) \leq X(P+1) \leq X(P+2) \leq \dots \leq X(2P+1).$$

La médiane est donc unique et égale à  $X(P+1)$ .

- si  $N$  est pair,  $N = 2P$ , la série sous forme brute classée est :

$$X(1) \leq \dots \leq X(P) \leq X(P+1) \leq \dots \leq X(2P).$$

Tout nombre de l’intervalle  $[X(P), X(P+1)]$  convient. Il existe différentes conventions, telles que  $\frac{X(P)+X(P+1)}{2}$  ou  $X(P)$ .

*Dans le contexte de ce cours, nous fixons la médiane comme étant égale à  $X(P)$ .*

Avec cette convention, la médiane dans le cas où  $N$  est pair ou impair satisfait à la définition suivante :

$$m = \min \left\{ x_i \mid i \in \{1, \dots, p\}, \phi_i \geq \frac{1}{2} \right\}.$$

*Remarque.* La médiane possède une unité : celle des valeurs de  $X$ .

**Définition 3.4.** Supposons que la variable  $X$  soit continue. La *classe médiane* est telle que au moins la moitié de l’effectif appartienne aux classes “inférieures ou égales” à cette classe et au moins la moitié appartienne aux classes “supérieures ou égales” à cette classe. De manière analogue au cas discret, il est plus aisé d’avoir une définition qui donne un nombre que l’on puisse calculer. On introduit donc la définition suivante.

La *médiane* d’une variable continue  $X$ , notée  $m$ , est la *plus petite* solution de l’équation,

$$F_X(x) = \frac{1}{2}, \quad (3.1)$$

où  $F_X$  est la fonction de répartition empirique de  $X$ . Autrement dit,

$$m = \min \left\{ x \in [a_0, a_p] \mid F_X(x) = \frac{1}{2} \right\}.$$

*Remarque.* Comme  $X$  est continue, d’après la proposition 2.1, sa fonction de répartition empirique  $F_X$  est continue. Donc  $F_X$  vérifie le théorème des valeurs intermédiaires, ce qui montre que l’équation (3.1) admet toujours au moins une solution. Comme l’intervalle  $[a_0, a_p]$  est compact, la solution est unique.

**Propriété 3.1.** La médiane d’une variable continue  $X$  satisfait à l’égalité suivante :

$$m = a_{i_0-1} + \frac{a_{i_0} - a_{i_0-1}}{\phi_{i_0} - \phi_{i_0-1}} \left( \frac{1}{2} - \phi_{i_0-1} \right),$$

où  $i_0 = \min \left\{ i \in \{1, \dots, p\} \mid F_X(a_i) \geq \frac{1}{2} \right\}$ .

*Démonstration.* La fonction de répartition empirique  $F_X$  de  $X$  étant croissante, il existe un unique  $i_0 \in \{1, \dots, p\}$  tel que :

$$F_X(a_{i_0-1}) < \frac{1}{2} \leq F_X(a_{i_0}), \quad \text{avec} \quad i_0 = \min \left\{ i \in \{1, \dots, p\} \mid F_X(a_i) \geq \frac{1}{2} \right\}.$$

De plus, on sait que  $d_{i_0} \neq 0$  car  $F_X(a_{i_0-1}) \neq F_X(a_{i_0})$ . On résout alors l'équation (3.1) en utilisant l'expression de  $F_X$  sur  $[a_{i_0-1}, a_{i_0}[$  :

$$\frac{1}{2} = F_X(m) = \phi_{i_0-1} + d_{i_0}(m - a_{i_0-1}) = \phi_{i_0-1} + \frac{\phi_{i_0} - \phi_{i_0-1}}{a_{i_0} - a_{i_0-1}}(m - a_{i_0-1})$$

en utilisant les expressions de l'effectif cumulé croissant et de la densité de proportion. On obtient ainsi :

$$m = a_{i_0-1} + \frac{a_{i_0} - a_{i_0-1}}{\phi_{i_0} - \phi_{i_0-1}} \left( \frac{1}{2} - \phi_{i_0-1} \right). \quad \square$$

On peut généraliser le principe de définition de la médiane, ce qui donne lieu à la notion de quantile.

**Définition 3.5.** Soit  $r \in ]0, 1]$ .

- Si la variable  $X$  est discrète, le *quantile d'ordre  $r$* , noté  $Q_r$ , est l'unique valeur  $x_{i_0}$ ,  $i_0 \in \{1, \dots, p\}$ , telle que  $\phi_{i_0-1} < r \leq \phi_{i_0}$  :

$$Q_r = \min \{x_i \mid i \in \{1, \dots, p\} \text{ et } \phi_i \geq r\}.$$

- Si la variable  $X$  est continue, le *quantile d'ordre  $r$* , noté  $Q_r$ , est la plus petite solution de l'équation  $F_X(x) = r$ , où  $F_X$  est la fonction de répartition empirique de  $X$  :

$$Q_r = \min \{x \in [a_0, a_p] \mid F_X(x) = r\}.$$

*Remarque.*

1. Comme la médiane, les quantiles possèdent une unité : celle des valeurs de  $X$ .
2. En prenant  $r = 1/2$ , on retrouve la définition de la médiane, donc  $m = Q_{\frac{1}{2}}$ .

**Définition 3.6.**

- Pour tout  $n \in \{1, \dots, 99\}$ , le  $n$ -ième *centile* est  $Q_{\frac{n}{100}}$ , le quantile d'ordre  $n/100$ .
- Pour tout  $n \in \{1, \dots, 9\}$ , le  $n$ -ième *décile* est  $Q_{\frac{n}{10}}$ , le quantile d'ordre  $n/10$ . Les déciles sont aussi notés  $d_1, \dots, d_9$ .
- Pour  $n \in \{1, 2, 3\}$ , le  $n$ -ième *quartile*, est  $Q_{\frac{n}{4}}$ , le quantile d'ordre  $n/4$ . Les quartiles sont aussi notés  $q_1, q_2, q_3$ .

*Remarque.* La médiane est également le 50-ième centile et le second quartile. De même, les premier et troisième quartiles sont respectivement les 25-ième et 75-ième centiles.

**Propriété 3.2.** Le quantile d'ordre  $r$  d'une variable continue  $X$  satisfait à l'égalité suivante :

$$Q_r = a_{i_0-1} + \frac{a_{i_0} - a_{i_0-1}}{\phi_{i_0} - \phi_{i_0-1}}(r - \phi_{i_0-1}), \quad (3.2)$$

où  $i_0 = \min \{i \in \{1, \dots, p\} \mid F_X(a_i) \geq r\}$ .

*Remarque.* La médiane est plus robuste que la moyenne : une ou plusieurs données erronées ne font pratiquement pas, voire pas du tout, changer la médiane, alors qu'elles peuvent affecter considérablement la moyenne.

*Exemple.* Pour le calcul des quantiles, on regarde les fréquences cumulées croissantes.

- *Ordinateurs.* On obtient,

$$m = 2, q_1 = 1, q_3 = 3, d_1 = 1, d_9 = 4, Q_{\frac{1}{100}} = 0, Q_{\frac{99}{100}} = 5.$$

- *Moyennes CC.* On utilise la formule (3.2) pour obtenir :

$$\begin{aligned} m &= 12 + \frac{4}{0.8056 - 0.4722} \left( \frac{1}{2} - 0.4722 \right) = 12.34 \\ q_1 &= 8 + \frac{4}{0.4722 - 0.1389} \left( \frac{1}{4} - 0.1389 \right) = 9.33 \\ q_3 &= 12 + \frac{4}{0.8056 - 0.4722} \left( \frac{3}{4} - 0.4722 \right) = 15.34 \\ d_1 &= 4 + \frac{4}{0.1389 - 0.0278} \left( \frac{1}{10} - 0.0278 \right) = 6.60 \\ d_9 &= 16 + \frac{4}{1 - 0.8056} \left( \frac{9}{10} - 0.8056 \right) = 17.94. \end{aligned}$$

### 3.1.4 RÉFLEXIONS SUR LE MODE, LA MOYENNE, ET LA MÉDIANE

Les trois paramètres de *tendance centrale* que sont le mode, la moyenne (arithmétique) et la médiane possèdent un certain nombre de propriétés en commun. Elles sont définies de façon *objective* : à partir des mêmes données, des personnes différentes aboutissent aux mêmes résultats numériques. Elles s'expriment dans la même unité que celle de la valeur de la variable. Elles peuvent être interprétées de façon facile et immédiate. Elles sont simples à calculer.

La moyenne (arithmétique) possède une propriété supplémentaire importante : sa valeur dépend de toutes les observations retenues (si on fait varier une des valeurs observées, la moyenne sera toujours modifiée au contraire du mode et de la médiane qui peuvent rester inchangées). C'est essentiellement pour cette raison que la moyenne, qui est plus longue à calculer que le mode ou la médiane, est considérée comme le principal paramètre de tendance centrale.

### 3.1.5 MOYENNES GÉOMÉTRIQUE, HARMONIQUE ET QUADRATIQUE

Il existe des types de moyennes autres que la moyenne arithmétique. Leur utilité sera vue en exercice. Comme précédemment, si la variable est continue, on prendra comme valeurs de la série les centres des classes. Strictement parlant, il s'agit dans ce cas d'approximation des moyennes.

#### Définition 3.7.

1. La *moyenne géométrique* d'une variable  $X$  est :

$$G = \left( x_1^{n_1} \times x_2^{n_2} \times \cdots \times x_p^{n_p} \right)^{1/N}.$$

2. La *moyenne harmonique* d'une variable  $X$  est :

$$\frac{1}{H} = \frac{1}{N} \sum_{i=1}^p n_i \frac{1}{x_i}.$$

3. La *moyenne quadratique* d'une variable  $X$  est :

$$Q = \sqrt{\frac{1}{N} \sum_{i=1}^p n_i \times x_i^2}.$$

*Remarque.* On a,  $\ln(G) = \frac{1}{N} \sum_{i=1}^p n_i \ln(x_i)$ .

**Propriété 3.3.** On a l'encadrement  $H \leq G \leq \bar{x}$ .

## 3.2 PARAMÈTRES DE DISPERSION

### 3.2.1 ÉTENDUE ET DISTANCE INTERQUARTILE

Rappelons qu'avec nos conventions, la plus petite valeur de la série est  $X(1)$  et la plus grande est  $X(N)$ .

**Définition 3.8.** L'*étendue* de la série, notée  $\delta_e$ , est la longueur du segment  $[X(1), X(N)]$  :

$$\delta_e = X(N) - X(1).$$

*Remarque.*

1. L'étendue possède une unité : celle des valeurs de  $X$ .
2. L'étendue *n'est pas très informative* car elle ne tient pas compte de la répartition des données dans le segment  $[X(1), X(N)]$ .

**Définition 3.9.** L'*intervalle inter-quartile* est le segment  $[q_1, q_3]$ . Il contient la moitié « centrale » des données de la série. La *distance inter-quartile*, notée  $\delta_q$ , est la longueur de l'intervalle inter-quartile :

$$\delta_q = q_3 - q_1.$$

*Remarque.*

1. La distance inter-quartile possède une unité : celle des valeurs de  $X$ .
2. La distance inter-quartile est plus précise que l'étendue car elle ne tient compte que de des données « proches » de la médiane en un certain sens.

### 3.2.2 VARIANCE ET ÉCART-TYPE

**Définition 3.10.** Si  $X$  est discrète (respectivement continue), sa *variance*, notée  $\text{Var}(X)$ , est la moyenne des écarts quadratiques des valeurs (respectivement des centres des classes) de  $X$  à sa moyenne :

$$\text{Var}(X) = \sum_{i=1}^p f_i (x_i - \bar{x})^2 = \frac{1}{N} \sum_{i=1}^p n_i (x_i - \bar{x})^2.$$

*Remarque.*

1. La variance n'a pas la même unité que les valeurs de  $X$ , mais celle de leur carré.
2. Lorsque la variable est discrète, avec les données brutes, la variance de  $X$  est le quotient de la somme des distances quadratiques à la moyenne des valeurs associées à chaque individu par la taille de la population :

$$\text{Var}(X) = \frac{1}{N} \sum_{u=1}^N (X(u) - \bar{x})^2.$$

**Proposition 3.2.** *La variance de  $X$  s'exprime également comme :*

$$\text{Var}(X) = \left( \sum_{i=1}^p f_i x_i^2 \right) - \bar{x}^2 = \left( \frac{1}{N} \sum_{i=1}^p n_i x_i^2 \right) - \bar{x}^2 = \left( \frac{1}{N} \sum_{u=1}^N X(u)^2 \right) - \bar{x}^2.$$

*Démonstration.* Montrons la première égalité, les deux autres étant simplement des réécritures. Il s'agit d'utiliser une identité remarquable :

$$\begin{aligned} \text{Var}(X) &= \sum_{i=1}^p f_i (x_i - \bar{x})^2 = \sum_{i=1}^p f_i (x_i^2 - 2x_i \bar{x} + \bar{x}^2) \\ &= \sum_{i=1}^p f_i x_i^2 - 2\bar{x} \sum_{i=1}^p f_i x_i + \bar{x}^2 \sum_{i=1}^p f_i \\ &= \sum_{i=1}^p f_i x_i^2 - 2\bar{x}(\bar{x}) + \bar{x}^2(1), \end{aligned}$$

par application de la définition de la moyenne  $\bar{x}$  et de la propriété 2.1. Le résultat suit.  $\square$

*Exemple 3.1.*

- *Ordinateurs.* On utilise la proposition précédente :

$$\begin{aligned} \text{Var}(X) &= \frac{1}{3774} (300 \times 0^2 + 876 \times 1^2 + 1235 \times 2^2 + 984 \times 3^2 + 225 \times 4^2 + 154 \times 5^2) - 2.11^2 \\ &= 1.40 \end{aligned}$$

ou de manière équivalente :

$$\begin{aligned} \text{Var}(X) &= (0.08 \times 0^2 + 0.23 \times 1^2 + 0.33 \times 2^2 + 0.26 \times 3^2 + 0.06 \times 4^2 + 0.04 \times 5^2) - 2.11^2 \\ &= 1.40. \end{aligned}$$

- *Moyennes CC.* La variable étant continue, il faut considérer les centres des classes pour obtenir :

$$\text{Var}(X) = \frac{1}{36} (2^2 \times 1 + 6^2 \times 4 + 10^2 \times 12 + 14^2 \times 12 + 18^2 \times 7) - 12.22^2 = 16.39,$$

ou de manière équivalente :

$$\begin{aligned} \text{Var}(X) &= (2^2 \times 0.0278 + 6^2 \times 0.1111 + 10^2 \times 0.3333 + 14^2 \times 0.3333 + 18^2 \times 0.1944) - 12.22^2 \\ &= 16.39, \end{aligned}$$

Comme somme de carrés, la variance est un nombre positif. C'est un bon indicateur de dispersion des données car la variance s'annule si et seulement si toutes les observations effectuées sont :

- identiques si  $X$  est discrète ;
- dans la même classe si  $X$  est continue.

Précisément, on a le résultat suivant :

**Théorème 3.1.** *La variance de  $X$  s'annule si et seulement si :*

$$\exists i_0 \in \{1, \dots, p\}, \forall i \neq i_0, n_i = 0. \quad (3.3)$$

*Auquel cas, un tel  $i_0$  est unique, donc toutes les observations sont identiques (respectivement dans la même classe) si  $X$  est discrète (respectivement continue).*

*Démonstration.* Supposons l'assertion (3.3) vérifiée. Alors  $N = n_1 + \dots + n_p = n_{i_0}$  et la moyenne de  $X$  est :

$$\bar{x} = \frac{1}{N} \sum_{i=1}^p n_i x_i = \frac{1}{n_{i_0}} n_{i_0} x_{i_0} = x_{i_0},$$

et la variance de  $X$  vaut :

$$\text{Var}(X) = \frac{1}{N} \sum_{i=1}^p n_i (x_i - \bar{x})^2 = \frac{1}{n_{i_0}} n_{i_0} (x_{i_0} - x_{i_0})^2 = 0.$$

Réciproquement, supposons  $\text{Var}(X) = 0$ ,

$$\begin{aligned} \text{Var}(X) = 0 &\iff \frac{1}{N} \sum_{i=1}^p n_i (x_i - \bar{x})^2 = 0 \iff \sum_{i=1}^p n_i (x_i - \bar{x})^2 = 0. \\ &\iff \forall i \in \{1, \dots, p\}, n_i (x_i - \bar{x})^2 = 0, \end{aligned}$$

car une somme de termes positifs n'est nulle que si chacun des termes la composant est nul. Ainsi, on obtient :

$$\forall i \in \{1, \dots, p\}, (n_i = 0 \text{ ou } x_i = \bar{x}).$$

Comme  $N \neq 0$ , il existe  $i_0 \in \{1, \dots, p\}$  tel que  $n_{i_0} \neq 0$ , ce qui entraîne  $\bar{x} = x_{i_0}$ . Soit alors  $i \neq i_0$ . On a  $x_i \neq x_{i_0}$ , donc  $x_i \neq \bar{x}$ , ce qui entraîne  $n_i = 0$  et conclut la preuve.  $\square$

**Définition 3.11.** L'écart-type de  $X$ , noté  $\sigma_X$ , est la racine carrée de la variance :  $\sigma_X = \sqrt{\text{Var}(X)}$ .

*Remarque.* L'écart-type est également un bon indicateur de dispersion car il vérifie la propriété du théorème 3.1. Mais de plus, l'écart-type a la même unité que les valeurs de  $X$ .

*Exemple.* Grâce aux calculs de l'exemple 3.1, on obtient directement  $\sigma_X = 1.18$  pour le nombre d'ordinateur et  $\sigma_X = 4.05$  pour les notes.

De même que pour la moyenne à la proposition 3.1, on peut étudier le comportement de la variance et de l'écart-type par changement de variables affine.

**Théorème 3.2.** *Soient  $a, b \in \mathbb{R}$  et  $Y$  la variable définie par  $Y = aX + b$ . Alors :*

$$\text{Var}(Y) = a^2 \text{Var}(X) \quad \text{et} \quad \sigma_Y = |a| \sigma_X.$$



*Démonstration.* Si la variance se comporte comme annoncé, on obtient :

$$\sigma_Y = \sqrt{\text{Var}(Y)} = \sqrt{a^2 \text{Var}(X)} = |a| \sqrt{\text{Var}(X)} = |a| \sigma_X.$$

Reste donc à montrer l'égalité sur les variances. Pour ce faire, on écrit :

$$\text{Var}(Y) = \sum_{i=1}^p f_i (y_i - \bar{y})^2,$$

avec  $f_i$  fréquence de la valeur (respectivement classe de centre)  $x_i$  si  $X$  est discrète (respectivement continue) et  $y_i = ax_i + b$  (voir proposition 3.1). Donc :

$$\text{Var}(Y) = \sum_{i=1}^p f_i ((ax_i + b) - (a\bar{x} + b))^2 = a^2 \sum_{i=1}^p f_i (x_i - \bar{x})^2 = a^2 \text{Var}(X),$$

comme escompté. □

### 3.3 BOX PLOT OU BOÎTE À MOUSTACHES

La boîte à moustaches, ou “box plot” en anglais, est une représentation graphique mettant en exergue certains des paramètres de position et de dispersion précédents. Elle permet de visualiser sommairement la répartition des données de la série statistique et les données “extrêmes”. Elle est constituée :

- d'un diagramme en boîte : un rectangle de bornes  $q_1$ ,  $q_3$  coupé au niveau de la médiane  $m$  et éventuellement également au niveau de la moyenne  $\bar{x}$  (alors signifié en pointillés) ;
  - de moustaches : deux segments joignant  $q_1$  à  $X(1)$  pour l'un et  $q_3$  à  $X(N)$  pour l'autre.
- La figure 3.1 représente l'allure générale d'une telle représentation.




FIGURE 3.1 – Allure d'une boîte à moustaches.

*Remarque.* Il existe des variantes sur les bornes des moustaches. Plutôt que de les faire aller jusqu'à  $X(1)$ ,  $X(N)$ , on peut les faire aller jusqu'aux premier et neuvième déciles, ou aux cinquième et 95-ième centiles, ou aux premier et 99-ième centiles, etc. On appelle alors outliers les données à l'extérieur des moustaches.

### 3.4 PARAMÈTRES DE FORME

#### 3.4.1 VARIABLE CENTRÉE RÉDUITE

**Définition 3.12.** Une variable  $X$  est dite *centrée* si elle est de moyenne arithmétique nulle. Elle est dite *réduite* si elle est de variance égale à 1.

**Propriété 3.4.** Soit  $X$  une variable, et  $Y$  la variable définie par,

$$Y = \frac{X - \bar{x}}{\sigma_X}.$$

Alors, la variable  $Y$  est centrée et réduite. Elle est appelée la variable centrée-réduite associée à la variable  $X$ .

*Démonstration.* Grâce aux formules de changement de variables affine pour la moyenne et la variance, on a :

$$\bar{y} = \frac{\bar{x} - \bar{x}}{\sigma_X} = 0 \quad \text{et} \quad \text{Var}(Y) = \frac{1}{\text{Var}(X)} \text{Var}(X) = 1.$$

□

Quand on transforme une variable en la variable centrée réduite associée, on retire à cette variable toute l'information concernant son échelle ou unité, et sa localisation. Il ne reste plus que des informations sur la forme de la distribution. Cette transformation permet de comparer plusieurs variables sur le plan de la forme, même si ce sont des variables exprimées dans des échelles différentes ou qui ont des moyennes complètement différentes.

#### 3.4.2 MOMENTS D'UNE DISTRIBUTION

**Définition 3.13.**

1. On appelle *moment à l'origine* d'ordre  $r \in \mathbb{N}$  le paramètre

$$m'_r = \sum_{i=1}^p f_i \cdot x_i^r = \frac{1}{N} \sum_{i=1}^p n_i \cdot x_i^r.$$

2. On appelle *moment centré* d'ordre  $r \in \mathbb{N}$  le paramètre

$$m_r = \sum_{i=1}^p f_i (x_i - \bar{x})^r = \frac{1}{N} \sum_{i=1}^p n_i (x_i - \bar{x})^r.$$

*Remarque.*

1. Pour une variable discrète, avec les données brutes, on a

$$m'_r = \frac{1}{N} \sum_{u=1}^N X(u)^r \quad \text{et} \quad m_r = \frac{1}{N} \sum_{u=1}^N (X(u) - \bar{x})^r.$$

2. La moyenne est le moment à l'origine d'ordre 1, et la variance le moment centré d'ordre 2, qui s'exprime également en fonction des moments à l'origine d'ordres 1 et 2 :

$$m_2 = \text{Var}(X) = \frac{1}{N} \sum_{u=1}^N X(u)^2 - \bar{x}^2 = m'_2 - (m'_1)^2.$$

### 3.4.3 COEFFICIENT D'ASYMÉTRIE DE FISHER

Une distribution est parfaitement *symétrique*, si les valeurs qu'elle prend sont également dispersées de part et d'autre de la moyenne. Dans ce cas, son mode, sa moyenne et sa médiane sont confondues, ses quartiles  $q_1$  et  $q_3$ , ses déciles  $d_1$  et  $d_9$  sont équidistants de la valeur centrale, et son histogramme admet un axe de symétrie (symétrie par rapport à la valeur de la moyenne).

Ce n'est pas le cas pour les distributions *asymétriques* ou *obliques*. On peut mesurer l'asymétrie d'une distribution au moyen du moment centré d'ordre 3 :

**Définition 3.14.** Le *coefficient d'asymétrie de Fisher* est la quantité suivante :

$$\gamma_1 = \frac{m_3}{\sigma_X^3} = \frac{\sum_{i=1}^p f_i(x_i - \bar{x}_i)^3}{\sigma_X^3} = \sum_{i=1}^p f_i \left( \frac{x_i - \bar{x}_i}{\sigma_X} \right)^3.$$

Il s'agit du moment à l'origine d'ordre 3 des données centrées-réduites.

Ce coefficient peut prendre des valeurs positives, négatives ou nulles :

- si la distribution est symétrique, il est nul,
- si la distribution est allongée à gauche (les grandes valeurs sont plus fréquentes que les petites), il est négatif,
- si la distribution est allongée à droite (les petites valeurs sont plus fréquentes que les grandes), il est positif.

*Exemple.*

- *Ordinateurs.* En rappelant que  $\bar{x} = 2.11$ ,  $\sigma_X = 1.18$  et en utilisant les données, on obtient :

$$\gamma_1 = \frac{1}{1.18^3} \frac{1}{3774} \left( 300 \times (0 - 2.11)^3 + 876 \times (1 - 2.11)^3 + 1235 \times (2 - 2.11)^3 + 984 \times (3 - 2.11)^3 + 225 \times (4 - 2.11)^3 + 154 \times (5 - 2.11)^3 \right) = 0.30.$$

- *Moyennes CC.* En rappelant que  $\bar{x} = 12.22$ ,  $\sigma_X = 4.05$ , et en utilisant les données (la variable étant continue, il faut considérer les centres des classes), on obtient :

$$\gamma_1 = \frac{1}{4.05^3} \frac{1}{36} \left( (2 - 12.22)^3 \times 1 + (6 - 12.22)^3 \times 4 + (10 - 12.22)^3 \times 12 + (14 - 12.22)^3 \times 12 + (18 - 12.22)^3 \times 7 \right) = -0.31.$$

### 3.4.4 COEFFICIENT D'APLATISSEMENT

L'aplatissement (ou kurtosis en anglais) est mesuré à l'aide du moment centré d'ordre 4 :

**Définition 3.15.**

1. Le *coefficient d'aplatissement de Pearson* est la quantité suivante :

$$\beta_2 = \frac{m_4}{\sigma_X^4} = \frac{\sum_{i=1}^p f_i(x_i - \bar{x}_i)^4}{\sigma_X^4} = \sum_{i=1}^p f_i \left( \frac{x_i - \bar{x}_i}{\sigma_X} \right)^4.$$

Il s'agit du moment à l'origine d'ordre 4 des données centrées-réduites.

2. Le *coefficient d'aplatissement de Fisher* ou *coefficient de Yule* est la quantité suivante :

$$\gamma_2 = \beta_2 - 3 = \frac{m_4}{\sigma_X^4} - 3.$$

Une distribution est dite :

- *mésokurtique* si  $\gamma_2 \simeq 0$  (la densité de la loi normale, ou courbe en cloche, est mésokurtique).
- *leptokurtique* si  $\gamma_2 > 0$  : son histogramme est plus pointu et possède des queues plus longues (distribution moins aplatie que la distribution normale).
- *platykurtique* si  $\gamma_2 < 0$  : son histogramme est plus arrondi et possède des queues plus courtes (distribution plus aplatie que la distribution normale).

*Exemple.*

- *Ordinateurs.* En rappelant que  $\bar{x} = 2.11$ ,  $\sigma_X = 1.18$  et en utilisant les données, on obtient :

$$\begin{aligned} \gamma_2 = \frac{1}{1.18^4} \frac{1}{3774} & \left( 300 \times (0 - 2.11)^4 + 876 \times (1 - 2.11)^4 + 1235 \times (2 - 2.11)^4 \right. \\ & \left. + 984 \times (3 - 2.11)^4 + 225 \times (4 - 2.11)^4 + 154 \times (5 - 2.11)^4 \right) - 3 = -0.11. \end{aligned}$$

- *Moyennes CC.* En rappelant que  $\bar{x} = 12.22$ ,  $\sigma_X = 4.05$ , et en utilisant les données (la variable étant continue, il faut considérer les centres des classes), on obtient :

$$\begin{aligned} \gamma_2 = \frac{1}{4.05^4} \frac{1}{36} & \left( (2 - 12.22)^4 \times 1 + (6 - 12.22)^4 \times 4 + (10 - 12.22)^4 \times 12 \right. \\ & \left. + (14 - 12.22)^4 \times 12 + (18 - 12.22)^4 \times 7 \right) - 3 = -0.40. \end{aligned}$$

### 3.5 COURBE DE CONCENTRATION DE LORENZ ET INDICE DE GINI

On dispose d'observations d'une variable décrivant une quantité correspondant à une richesse, par exemple le chiffre d'affaires, le patrimoine, les salaires. Il est donc naturel de supposer les données positives, ce qui implique en particulier que  $\bar{x} > 0$ .

On se pose alors des questions sur la répartition égalitaire ou non de ces richesses : les salaires sont-ils répartis de manière égalitaire ? Le chiffre d'affaire des entreprises d'un secteur est-il concentré entre les mains d'une poignée d'entreprises au détriment de toutes les autres ? Quelle fortune représentent les 3% de familles les plus riches de France ?

#### 3.5.1 COURBE DE CONCENTRATION DE LORENZ

**Définition 3.16.**

1. On appelle *masses cumulées* de la variable  $X$  les quantités définies, pour  $1 \leq i \leq p$ , par :

$$\sum_{j=1}^i n_j x_j.$$

2. On appelle *masses cumulées relatives* de la variable  $X$  les quantités définies, pour  $1 \leq i \leq p$ , par :

$$M_i = \frac{\sum_{j=1}^i n_j x_j}{\sum_{j=1}^p n_j x_j} = \frac{\sum_{j=1}^i n_j x_j}{N \bar{x}} = \frac{\sum_{j=1}^i f_j x_j}{\bar{x}}.$$

3. On appelle *masse totale* le dénominateur,  $\sum_{j=1}^p n_j x_j = N \bar{x}$ .  
 4. On appelle *courbe de concentration de Lorenz* la ligne polygonale qui joint les points  $O$  et  $P_1, \dots, P_p$  définis par leurs coordonnées :

$$O = (0, 0), \quad P_1 = (\phi_1, M_1), \quad P_2 = (\phi_2, M_2), \dots, \quad P_p = (\phi_p, M_p) = (1, 1), \quad (3.4)$$

où on rappelle que les  $(\phi_i)_{i \in \{1, \dots, p\}}$  sont les fréquences cumulées croissantes.

**Propriété 3.5.** Pour tout  $i \in \{1, \dots, p\}$  on a,  $0 \leq M_i \leq 1$ . De plus, la courbe de concentration de Lorenz est toujours située sous la droite d'équation  $y = x$ .

*Démonstration.* La première partie est une conséquence du fait que les données soient supposées positives. Pour démontrer la seconde partie, il suffit de voir que, pour tout  $i \in \{1, \dots, p\}$ ,  $M_i \leq \phi_i$ . On rappelle que,

$$M_i = \frac{\sum_{j=1}^i n_j x_j}{N \bar{x}} \quad \text{et} \quad \phi_i = \sum_{j=1}^i \frac{n_j}{N}.$$

Ainsi, on a les équivalences suivantes :

$$M_i \leq \phi_i \Leftrightarrow \frac{\sum_{j=1}^i n_j x_j}{\bar{x}} \leq \sum_{j=1}^i n_j \Leftrightarrow \sum_{j=1}^i n_j x_j \leq \sum_{j=1}^i n_j \bar{x} \Leftrightarrow 0 \leq \sum_{j=1}^i n_j (\bar{x} - x_j) \quad (*).$$

Soit  $i_0$  tel que  $x_{i_0} \leq \bar{x} \leq x_{i_0+1}$ .

- si  $i \leq i_0$ , alors  $\forall j \leq i$ ,  $x_j \leq x_{i_0} \leq \bar{x}$  et donc  $\bar{x} - x_j \geq 0$ , et la condition (\*) est vérifiée.
- si  $i > i_0$ , la condition (\*) à démontrer peut se ré-écrire en la condition équivalente,

$$\sum_{j=i_0+1}^i n_j (x_j - \bar{x}) \leq \sum_{j=1}^{i_0} n_j (\bar{x} - x_j) \quad (**).$$

Or,

$$\begin{aligned} \sum_{j=i_0+1}^i n_j (x_j - \bar{x}) &\leq \sum_{j=i_0+1}^p n_j (x_j - \bar{x}), \text{ car les termes que l'on rajoute sont positifs} \\ &= \sum_{j=1}^p n_j (x_j - \bar{x}) - \sum_{j=1}^{i_0} n_j (x_j - \bar{x}) \\ &= \sum_{j=1}^p n_j (x_j - \bar{x}) + \sum_{j=1}^{i_0} n_j (\bar{x} - x_j) \\ &= \sum_{j=1}^{i_0} n_j (\bar{x} - x_j), \end{aligned}$$

car  $\sum_{j=1}^p n_j (x_j - \bar{x}) = N \bar{x} - (\sum_{j=1}^p n_j) \bar{x} = N \bar{x} - N \bar{x} = 0$ . Ceci achève la preuve de la condition (\*\*) et donc du résultat.

□

*Remarque.* La diagonale représente la répartition égalitaire des richesses : 20% de la population détient 20% des revenus, 60% en détient 60% des revenus, etc. Plus la courbe est éloignée de la diagonale, plus la répartition des richesses est inégalitaire.


*Exemple 3.2.* On connaît la répartition des salaires mensuels dans une entreprise :

Salaires	[600,900[	[900,1200[	[1200,1500[	[1500,1800[	[1800,2100[	[2100,2400[
Effectif	31	95	101	59	36	18

Afin de tracer la courbe de Lorenz, il faut calculer les fréquences cumulées ainsi que les masses cumulées relatives. On obtient le tableau suivant :

Salaires	[600,900[	[900,1200[	[1200,1500[	[1500,1800[	[1800,2100[	[2100,2400[	Total
Effectif	31	95	101	59	36	18	340
Centre des classes	750	1050	1350	1650	1950	2250	pas de sens
Fréquence	0.0912	0.2794	0.2971	0.1735	0.1059	0.0529	1
Fréquence cumulée croissante	0.0912	0.3706	0.6676	0.8412	0.9471	1	pas de sens
Masse cumulée relative	0.0497	0.2631	0.5549	0.7631	0.9133	1	pas de sens

On obtient la courbe suivante :



### 3.5.2 INDICE DE GINI

**Définition 3.17.** On appelle *indice de Gini*, noté  $I_G$ , le réel :  $I_G = 2S$  où  $S$  est la surface de la partie du carré unité délimitée par la courbe de Lorenz et la diagonale d'équation  $y = x$ .

*Remarque.* On a toujours  $0 \leq I_G \leq 1$ . Plus  $I_G$  est élevé, plus la série est inégalitaire, car la courbe de Lorenz est d'autant plus éloignée de la diagonale. Cependant,  $I_G$  donne moins d'information que la courbe étant donné qu'il représente l'aire sous la courbe et non pas la courbe elle-même.

**Proposition 3.3.** *L'indice de Gini est égal à :*

$$I_G = 1 - \sum_{i=1}^p (M_{i-1} + M_i) \times f_i.$$

*Démonstration.* Pour calculer l'indice de Gini, on utilise la *méthode des trapèzes*. On observe que la surface  $S$  est égal à l'aire du triangle dont les sommets sont  $(0,0)$ ,  $(0,1)$ ,  $(1,1)$ , soit  $\frac{1}{2}$ , à laquelle il faut retrancher l'aire  $A$  comprise entre la courbe de Lorenz et l'axe des abscisses. Cette aire  $A$  n'est autre que la somme des aires des trapèzes dont les sommets sont  $(\phi_{i-1}, 0)$ ,  $(\phi_{i-1}, M_{i-1})$ ,  $(\phi_i, M_i)$ ,  $(\phi_i, 0)$  pour  $i \in \{1, \dots, p\}$  (avec la convention  $\phi_0 = M_0 = 0$ ). On rappelle que l'aire d'un trapèze se calcule de la façon suivante :

$$\frac{\text{petite base} + \text{grande base}}{2} \times \text{hauteur},$$

ce qui donne :

$$\begin{aligned} I_G = 2S &= 2(0.5 - A) = 1 - 2A = 1 - 2 \sum_{i=1}^p \frac{M_{i-1} + M_i}{2} \times (\phi_i - \phi_{i-1}) \\ &= 1 - \sum_{i=1}^p (M_{i-1} + M_i) \times (\phi_i - \phi_{i-1}) = 1 - \sum_{i=1}^p (M_{i-1} + M_i) \times f_i. \end{aligned}$$

□

*Exemple.* Avec les données de l'exemple 3.2, on obtient :

$$\begin{aligned} I_G = 1 - \bigg( (0 + 0.05) \times 0.09 + (0.05 + 0.26) \times 0.28 + (0.26 + 0.55) \times 0.30 + (0.55 + 0.76) \times 0.17 \\ + (0.76 + 0.91) \times 0.11 + (1 + 0.91) \times 0.05 \bigg) = 0.16. \end{aligned}$$

# CHAPITRE 4

## STATISTIQUE DESCRIPTIVE BI-VARIÉE

Considérons une population  $\mathcal{P}$  de taille  $N$ ,  $\mathcal{P} = \{1, \dots, N\}$ , sur laquelle on étudie *deux* variables  $X$  et  $Y$ . Ces variables peuvent être soit qualitatives, quantitatives discrètes ou continues.

Le but de cette section est d'étudier les relations entre  $X$  et  $Y$ , ce qui revient, mathématiquement, à étudier les propriétés du *couple*  $(X, Y)$ . On définit dans ce chapitre essentiellement deux types de quantités, celles dites :

- *marginales* qui ne dépendent que d'un *seul* critère mais pas des deux ;
- *conditionnelles* qui renseignent sur un critère *en fonction* des valeurs ou modalités de l'autre.

Rappelons les notations pour les séries statistiques.

- On a la *série statistique double* sous forme brute :

$$\{(X(1), Y(1)), \dots, (X(N), Y(N))\}.$$

- Les modalités/valeurs/centre des classes de la variable  $X$  sont :

$$\{x_1, \dots, x_p\}.$$

*N.B : afin de simplifier les notations, pour une variable qualitative, on note  $x_i$  les modalités au lieu de  $m_i$  précédemment.*

Les modalités/valeurs/centre des classes de la variable  $Y$  sont :

$$\{y_1, \dots, y_q\}.$$

De plus, ces notations respectent l'ordre naturel dans le cas d'une variable qualitative ordinaire ou quantitative.

Les modalités/valeurs/centre des classes du couple  $(X, Y)$  sont les  $p \times q$  données :

$$\{(x_1, y_1), (x_1, y_2), \dots, (x_p, y_q)\}.$$

*Remarque.*

- Désormais, l'indice  $i$  servira exclusivement à indexer des données relatives au premier membre du couple, soit  $X$ , et l'indice  $j$  exclusivement à indexer des données relatives au second, soit  $Y$ .
- Comme déjà expliqué dans le chapitre précédent, travailler avec une variable continue dont les valeurs ne sont pas regroupées en classes revient à considérer cette variable comme discrète.



## 4.1 DISTRIBUTIONS MARGINALES ET CONDITIONNELLES

Il est naturel, dans un premier temps, de regarder le couple  $(X, Y)$  comme *un seul* critère d'observation. On a alors les mêmes notions qu'au chapitre 1 :

### Définition 4.1.

- Soient  $i \in \{1, \dots, p\}$  et  $j \in \{1, \dots, q\}$ . L'*effectif* du couple  $(x_i, y_j)$ , noté  $n_{ij}$ , est le nombre d'individus associés à la fois à  $x_i$  pour  $X$  et à  $y_j$  pour  $Y$  et sa *fréquence*, noté  $f_{ij}$ , est le quotient de son effectif par la taille de la population :

$$n_{ij} = \text{card}\{u \in \mathcal{P} | X(u) = x_i \text{ et } Y(u) = y_j\} \quad \text{et} \quad f_{ij} = \frac{n_{ij}}{N}.$$

- Soit  $i \in \{1, \dots, p\}$  (respectivement  $j \in \{1, \dots, q\}$ ). L'*effectif marginal* de  $x_i$  (respectivement  $y_j$ ), noté  $n_{i\cdot}$  (respectivement  $n_{\cdot j}$ ), est l'effectif de  $x_i$  (respectivement  $y_j$ ) pour la série simple de  $X$  (respectivement  $Y$ ) :

$$n_{i\cdot} = \sum_{j=1}^q n_{ij} \quad \text{et} \quad n_{\cdot j} = \sum_{i=1}^p n_{ij}.$$

- La *fréquence marginale* de  $x_i$  (respectivement  $y_j$ ), notée  $f_{i\cdot}$  (respectivement  $f_{\cdot j}$ ), est alors le quotient de l'effectif marginal de  $x_i$  (respectivement  $y_j$ ) par la taille de la population :

$$f_{i\cdot} = \frac{n_{i\cdot}}{N} = \sum_{j=1}^q f_{ij} \quad \text{et} \quad f_{\cdot j} = \frac{n_{\cdot j}}{N} = \sum_{i=1}^p f_{ij}.$$

*Remarque.* Les effectifs/fréquences marginaux sont également les effectifs/fréquences pour les séries statistiques simples de  $X$  ou de  $Y$ .

### Propriété 4.1.

$$\begin{aligned} \sum_{i=1}^p \sum_{j=1}^q n_{ij} &= \sum_{i,j} n_{ij} = N, & \sum_{i,j} f_{ij} &= 1, \\ \sum_{i=1}^p n_{i\cdot} &= \sum_{j=1}^q n_{\cdot j} = N & \text{et} & \sum_{i=1}^p f_{i\cdot} = \sum_{j=1}^q f_{\cdot j} = 1. \end{aligned}$$

*Démonstration.* Les deux premières égalités sont évidentes. Par symétrie entre  $X$  et  $Y$ , il suffit de démontrer le résultat pour les sommes des  $n_{i\cdot}$  et  $f_{i\cdot}$ . De plus, en divisant par  $N$ , on déduit du résultat sur la somme des  $n_{i\cdot}$  celui sur la somme des  $f_{i\cdot}$ . On calcule donc :

$$\sum_{i=1}^p n_{i\cdot} = \sum_{i=1}^p \left( \sum_{j=1}^q n_{ij} \right) = \sum_{i,j} n_{ij} = N,$$

comme attendu. □

**Définition 4.2.** Le *tableau de contingence des effectifs* du couple de variables  $(X, Y)$  est un tableau dans lequel les valeurs/classes/modalités de  $X$  sont en lignes, celles de  $Y$  en colonnes et, pour tout  $i \in \{1, \dots, p\}$  et  $j \in \{1, \dots, q\}$ , l'effectif  $n_{ij}$  se situe à l'intersection de la ligne  $i$

et de la colonne  $j$ . On rajoute une colonne à droite qui contient les effectifs marginaux des  $x_i$  (obtenus en faisant la somme des effectifs sur les colonnes) et une ligne en bas qui contient les effectifs marginaux des  $y_j$  (obtenus en faisant la somme des effectifs sur les lignes). La case en bas à droite contient l'effectif total  $N$ .

On peut aussi faire le *tableau de contingence des fréquences* avec les fréquences/fréquences marginales plutôt que les effectifs/effectifs marginaux.

$X \backslash Y$	$y_1$	$\cdots$	$y_j$	$\cdots$	$y_q$	Total
$x_1$	$n_{11}$	$\cdots$	$n_{1j}$	$\cdots$	$n_{1q}$	$n_{1\cdot}$
$\vdots$	$\vdots$		$\vdots$			$\vdots$
$x_i$	$n_{i1}$	$\cdots$	$n_{ij}$	$\cdots$	$n_{iq}$	$n_{i\cdot}$
$\vdots$	$\vdots$		$\vdots$			$\vdots$
$x_p$	$n_{p1}$	$\cdots$	$n_{pj}$	$\cdots$	$n_{pq}$	$n_{p\cdot}$
Total	$n_{\cdot 1}$	$\cdots$	$n_{\cdot j}$	$\cdots$	$n_{\cdot q}$	$N$

Tableau de contingence des effectifs du couple de variables  $(X, Y)$

$X \backslash Y$	$y_1$	$\cdots$	$y_j$	$\cdots$	$y_q$	Total
$x_1$	$f_{11}$	$\cdots$	$f_{1j}$	$\cdots$	$f_{1q}$	$f_{1\cdot}$
$\vdots$	$\vdots$		$\vdots$			$\vdots$
$x_i$	$f_{i1}$	$\cdots$	$f_{ij}$	$\cdots$	$f_{iq}$	$f_{i\cdot}$
$\vdots$	$\vdots$		$\vdots$			$\vdots$
$x_p$	$f_{p1}$	$\cdots$	$f_{pj}$	$\cdots$	$f_{pq}$	$f_{p\cdot}$
Total	$f_{\cdot 1}$	$\cdots$	$f_{\cdot j}$	$\cdots$	$f_{\cdot q}$	1

Tableau de contingence des fréquences du couple  $(X, Y)$ .

*Remarque.* Un tableau de contingence se lit comme une matrice : le premier indice est celui de la ligne et le second celui de la colonne.

En extrayant une colonne (respectivement une ligne) du tableau de contingence, on obtient une *distribution conditionnelle* de  $X$  (respectivement de  $Y$ ). Précisément, l'extraction de la colonne  $j$  (respectivement de la ligne  $i$ ) permet de répondre à la question « Sachant que  $Y$  vaut  $y_j$  (respectivement  $X$  vaut  $x_i$ ), comment se comporte  $X$  (respectivement  $Y$ ) ? » Ainsi, une distribution conditionnelle est l'étude d'un critère lorsque l'autre reste fixe – à une valeur ou modalité connue. On note  $X|_{Y=y_j}$  (respectivement  $Y|_{X=x_i}$ ) la *distribution conditionnelle de  $X$  sachant  $Y = y_j$*  (respectivement de  $Y$  sachant  $X = x_i$ ).

**Définition 4.3.** Soient  $i \in \{1, \dots, p\}$  et  $j \in \{1, \dots, q\}$ . La *fréquence conditionnelle* de  $x_i$  sachant  $y_j$  (respectivement  $y_j$  sachant  $x_i$ ), notée  $f_{i|Y=y_j}$  ou  $f_{i|j}$  (respectivement  $f_{j|X=x_i}$  ou  $f_{j|i}$ ), est la fréquence d'occurrence de  $x_i$  dans la colonne  $j$  (respectivement  $y_j$  dans la ligne  $i$ ) du tableau de contingence :

$$f_{i|Y=y_j} = \frac{n_{ij}}{n_{\cdot j}} \quad \text{et} \quad f_{j|X=x_i} = \frac{n_{ij}}{n_{i\cdot}}.$$

**Propriété 4.2.** Les fréquences conditionnelles vérifient les égalités suivantes :

$$\forall j \in \{1, \dots, q\}, \sum_{i=1}^p f_{i|Y=y_j} = 1 \quad \text{et} \quad \forall i \in \{1, \dots, p\}, \sum_{j=1}^q f_{j|X=x_i} = 1.$$

*Démonstration.* De nouveau par symétrie entre  $X$  et  $Y$ , il suffit de montrer, par exemple, la première égalité. Soit donc  $j \in \{1, \dots, q\}$ . On écrit :

$$\sum_{i=1}^p f_{i|Y=y_j} = \sum_{i=1}^p \frac{n_{ij}}{n_{.j}} = \frac{1}{n_{.j}} \sum_{i=1}^p n_{ij} = \frac{1}{n_{.j}} n_{.j} = 1. \quad \square$$

**Définition 4.4.** Le tableau des *profils-colonne* représente les distributions conditionnelles de  $X|Y$ . On ajoute une ligne en bas avec les totaux, égaux à 1 d'après la propriété ci-dessus. Le tableau des *profils-ligne* représente les distributions conditionnelles  $Y|X$ . On ajoute une colonne à droite avec les totaux, égaux à 1 d'après la propriété ci-dessus.

$X Y \backslash Y$	$y_1$	$\dots$	$y_q$
$x_1$	$f_{1 Y=y_1}$	$\dots$	$f_{1 Y=y_q}$
$\vdots$	$\vdots$		$\vdots$
$x_p$	$f_{p Y=y_1}$	$\dots$	$f_{p Y=y_q}$
Total	1	$\dots$	1

Tableau des profils-colonne

$X \backslash Y X$	$y_1$	$\dots$	$y_q$	Total
$x_1$	$f_{1 X=x_1}$	$\dots$	$f_{q X=x_1}$	1
$\vdots$	$\vdots$			$\vdots$
$x_p$	$f_{1 X=x_p}$	$\dots$	$f_{q X=x_p}$	1

Tableau des profils-ligne

*Remarque.* Un calcul simple donne pour tout  $i \in \{1, \dots, p\}$  et  $j \in \{1, \dots, q\}$  :

$$f_{ij} = f_{i|Y=y_j} f_{.j} \quad \text{et} \quad f_{ij} = f_{j|X=x_i} f_{i.}$$

## 4.2 INDÉPENDANCE

Une question centrale dans les relations entre variables est celle de l'indépendance.

### 4.2.1 DÉFINITION

**Définition 4.5.** Les variables  $X$  et  $Y$  sont dites *indépendantes* lorsque :

$$\forall (i, j) \in \{1, \dots, p\} \times \{1, \dots, q\}, \quad f_{ij} = f_{i.} f_{.j}. \quad (4.1)$$

**Proposition 4.1.** Soient deux variables  $X, Y$ . Les assertions suivantes sont équivalentes :

- (i)  $X$  et  $Y$  sont indépendantes.
- (ii)  $\forall (i, j) \in \{1, \dots, p\} \times \{1, \dots, q\}, \quad n_{ij} = \frac{n_{i.} n_{.j}}{N}$ .
- (iii)  $\forall (i, j) \in \{1, \dots, p\} \times \{1, \dots, q\}, \quad f_{i|Y=y_j} = f_{i.}$
- (iv)  $\forall (i, j) \in \{1, \dots, p\} \times \{1, \dots, q\}, \quad f_{j|X=x_i} = f_{.j}$ .

*Démonstration.* Il suffit de modifier l'écriture de l'égalité (4.1) définissant l'indépendance. On considère donc  $i \in \{1, \dots, p\}$  et  $j \in \{1, \dots, q\}$ . Pour l'équivalence entre les points (i) et (ii) on écrit :

$$f_{ij} = f_{i\cdot} f_{\cdot j} \iff \frac{n_{ij}}{N} = \frac{n_{i\cdot} n_{\cdot j}}{N N} \iff n_{ij} = \frac{n_{i\cdot} n_{\cdot j}}{N}.$$

Pour l'équivalence entre les points (ii) et (iii) on écrit :

$$n_{ij} = \frac{n_{i\cdot} n_{\cdot j}}{N} \iff \frac{n_{ij}}{n_{\cdot j}} = \frac{n_{i\cdot}}{N} \iff f_{i|Y=y_j} = f_{i\cdot}.$$

Et de façon similaire :

$$n_{ij} = \frac{n_{i\cdot} n_{\cdot j}}{N} \iff \frac{n_{ij}}{n_{i\cdot}} = \frac{n_{\cdot j}}{N} \iff f_{j|X=x_i} = f_{\cdot j},$$

on obtient l'équivalence entre les points (ii) et (iv). □

#### 4.2.2 ÉCART À L'INDÉPENDANCE

Étant donné les variables  $X$  et  $Y$ , on s'intéresse à savoir si elles sont indépendantes ou non ; et à quantifier l'écart à l'indépendance. Pour cela, on peut calculer la quantité suivante.

**Définition 4.6.** Le *chi-carré observé* est :

$$\chi^2 = N \sum_{i,j} \frac{(f_{ij} - f_{i\cdot} f_{\cdot j})^2}{f_{i\cdot} f_{\cdot j}} = \sum_{i,j} \left( \frac{n_{i\cdot} n_{\cdot j}}{N} \right)^{-1} \left( n_{ij} - \frac{n_{i\cdot} n_{\cdot j}}{N} \right)^2.$$

**Propriété 4.3.** Le  $\chi^2$  est toujours positif ou nul et,

$$\chi^2 = 0 \iff \text{les variables } X \text{ et } Y \text{ sont indépendantes.}$$

Il se trouve que le  $\chi^2$  observé croît avec la taille de la population. Pour cette raison, il est utile de le renormaliser de manière adéquate.

**Définition 4.7.** Le *coefficient  $V$  de Cramer* du couple de variables  $(X, Y)$  est :

$$V = \sqrt{\frac{\chi^2}{N \min(p-1, q-1)}}.$$

**Propriété 4.4.** Le coefficient  $V$  de Cramer vérifie :

$$0 \leq V \leq 1,$$

et  $V = 0$  si et seulement si les variables sont indépendantes.

Ainsi le  $V$  de Cramer permet de mesurer l'écart à l'indépendance et sa taille ne dépend pas de la taille de la population.

### 4.3 NUAGE DE POINTS, RÉSUMÉS NUMÉRIQUES

Cette section n'a de sens que si les variables  $X$  et  $Y$  sont quantitatives, discrètes ou continues et regroupées en classes, ce que nous supposons dans la suite.

### 4.3.1 NUAGE DE POINTS

Rappelons que nous avons à disposition la statistique double,

$$\{(X(1), Y(1)), \dots, (X(N), Y(N))\}.$$

Cette dernière peut être représentée par un nuage de  $N$  points dans  $\mathbb{R}^2$ , noté  $\mathcal{N}(\mathcal{P})$  :

$$\mathcal{N}(\mathcal{P}) = \{(X(u), Y(u)) \in \mathbb{R}^2 : u \in \{1, \dots, N\}\}.$$

### 4.3.2 MOYENNE, VARIANCE, ÉCART-TYPE

En considérant les variables  $X$  et  $Y$  indépendamment l'une de l'autre, on peut définir tous les paramètres du chapitre 3, que l'on qualifie alors de *marginal*.

#### LES MOYENNES MARGINALES

En reprenant les définitions du chapitre 3, nous avons :

$$\bar{x} = \sum_{i=1}^p f_{i.} x_i = \sum_{i=1}^p \left( \sum_{j=1}^q f_{ij} \right) x_i = \sum_{i,j} f_{ij} x_i \quad \text{et} \quad \bar{y} = \sum_{j=1}^q f_{.j} y_j = \sum_{j=1}^q \left( \sum_{i=1}^p f_{ij} \right) y_j = \sum_{i,j} f_{ij} y_j.$$

Si les variables  $X$  et  $Y$  sont discrètes, à partir des données brutes, on a :

$$\bar{x} = \frac{1}{N} \sum_{u=1}^N X(u), \quad \text{et} \quad \bar{y} = \frac{1}{N} \sum_{u=1}^N Y(u).$$

**Définition 4.8.** Le point  $G = (\bar{x}, \bar{y})$  est appelé le *barycentre* ou *centre de gravité* du nuage de points.

La proposition suivante montre que la moyenne est linéaire.

**Proposition 4.2.** Soient  $a, b \in \mathbb{R}$ . La moyenne  $\bar{z}$  de la variable  $Z = aX + bY$  s'écrit :

$$\bar{z} = a\bar{x} + b\bar{y}.$$

*Démonstration.* La variable  $Z = aX + bY$  prend comme valeurs  $z_{ij} = ax_i + by_j$ , pour  $i \in \{1, \dots, p\}$ ,  $j \in \{1, \dots, q\}$ , avec  $f_{ij}$  comme fréquence pour la valeur  $z_{ij}$ . Ainsi, sa moyenne  $\bar{z}$  est :

$$\bar{z} = \sum_{i,j} f_{ij} z_{ij} = \sum_{i,j} f_{ij} (ax_i + by_j) = a \sum_{i,j} f_{ij} x_i + b \sum_{i,j} f_{ij} y_j = a\bar{x} + b\bar{y}. \quad \square$$

**LES VARIANCES ET ÉCARTS-TYPES MARGINAUX**

D'après le chapitre 3, nous avons :

$$\begin{aligned}\text{Var}(X) &= \sum_{i=1}^p f_{i\cdot} (x_i - \bar{x})^2 = \sum_{i=1}^p \left( \sum_{j=1}^q f_{ij} \right) (x_i - \bar{x})^2 = \sum_{i,j} f_{ij} (x_i - \bar{x})^2 \\ \text{Var}(Y) &= \sum_{j=1}^q f_{\cdot j} (y_j - \bar{y})^2 = \sum_{j=1}^q \left( \sum_{i=1}^p f_{ij} \right) (y_j - \bar{y})^2 = \sum_{i,j} f_{ij} (y_j - \bar{y})^2.\end{aligned}$$

Les écarts-types  $\sigma_X, \sigma_Y$  sont les racines des variances  $\text{Var}(X), \text{Var}(Y)$ .

Si les variables  $X$  et  $Y$  sont discrètes, à partir des données brutes, on a :

$$\text{Var}(X) = \frac{1}{N} \sum_{u=1}^N (X(u) - \bar{x})^2, \quad \text{et} \quad \text{Var}(Y) = \frac{1}{N} \sum_{u=1}^N (Y(u) - \bar{y})^2.$$

*Attention, à la différence de la moyenne, la variance n'est pas linéaire. Afin de calculer la variance d'une combinaison linéaire de variables, nous devons d'abord introduire la covariance.*

**4.3.3 COVARIANCE**

Soient  $X, Y$  deux variables quantitatives.

**Définition 4.9.** La *covariance* de  $X$  et  $Y$ , notée  $\text{Cov}(X, Y)$ , est la moyenne des produits des écarts des valeurs ou centres des classes de  $X$  et  $Y$  à leur moyenne respective :

$$\text{Cov}(X, Y) = \sum_{i,j} f_{ij} (x_i - \bar{x})(y_j - \bar{y}) = \frac{1}{N} \sum_{i,j} n_{ij} (x_i - \bar{x})(y_j - \bar{y}).$$

*Remarque.*

1. La covariance possède une unité : celle du produit des unités de  $X$  et  $Y$ .
2. La covariance est symétrique :  $\text{Cov}(X, Y) = \text{Cov}(Y, X)$ .
3. En faisant  $Y = X$ , on obtient  $\text{Cov}(X, X) = \text{Var}(X)$ .
4. Si les variables  $X$  et  $Y$  sont discrètes, à partir des données brutes on a :

$$\text{Cov}(X, Y) = \frac{1}{N} \sum_{u=1}^N (X(u) - \bar{x})(Y(u) - \bar{y}).$$

**Proposition 4.3.** La covariance de  $X$  et  $Y$  vérifie les propriétés suivantes :

1. La covariance de  $X$  et  $Y$  s'exprime également comme :

$$\text{Cov}(X, Y) = \left( \sum_{i,j} f_{ij} x_i y_j \right) - \bar{x} \bar{y} = \left( \frac{1}{N} \sum_{i,j} n_{ij} x_i y_j \right) - \bar{x} \bar{y}.$$

Si les variables  $X$  et  $Y$  sont discrètes, à partir des données brutes on a :

$$\text{Cov}(X, Y) = \left( \frac{1}{N} \sum_{u=1}^N X(u) Y(u) \right) - \bar{x} \bar{y}.$$

2. Soient  $a, b, c, d \in \mathbb{R}$ . On a la formule de changement de variables suivante :

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y).$$

3. Soient  $a, b \in \mathbb{R}$ . La variance de la variable  $aX + bY$  s'écrit :

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + 2ab \text{Cov}(X, Y) + b^2 \text{Var}(Y).$$

*Démonstration.* Pour le point 1, on développe la formule de la covariance :

$$\begin{aligned} \text{Cov}(X, Y) &= \sum_{i,j} f_{ij}(x_i - \bar{x})(y_j - \bar{y}) = \sum_{i,j} f_{ij}(x_i y_j - x_i \bar{y} - y_j \bar{x} + \bar{x} \bar{y}) \\ &= \left( \sum_{i,j} f_{ij} x_i y_j \right) - \bar{y} \left( \sum_{i,j} f_{ij} x_i \right) - \bar{x} \left( \sum_{i,j} f_{ij} y_j \right) + \bar{x} \bar{y} \left( \sum_{i,j} f_{ij} \right), \end{aligned}$$

et en utilisant :

$$\bar{x} = \sum_{i,j} f_{ij} x_i, \quad \bar{y} = \sum_{i,j} f_{ij} y_j \quad \text{et} \quad \sum_{i,j} f_{ij} = 1,$$

on obtient le résultat.

Pour le point 2, on reprend la définition de la covariance sachant que les moyennes de  $aX + b$  et  $cY + d$  sont respectivement  $a\bar{x} + b$  et  $c\bar{y} + d$  :

$$\begin{aligned} \text{Cov}(aX + b, cY + d) &= \sum_{i,j} f_{ij}((ax_i + b) - (a\bar{x} + b))((cy_j + d) - (c\bar{y} + d)) \\ &= ac \sum_{i,j} f_{ij}(x_i - \bar{x})(y_j - \bar{y}) = ac \text{Cov}(X, Y). \end{aligned}$$

Pour le point 3, posons  $Z = aX + bY$ . Alors, d'après la proposition 4.2,  $\bar{z} = a\bar{x} + b\bar{y}$ . Ainsi,

$$\begin{aligned} \text{Var}(aX + bY) &= \text{Var } Z = \sum_{i,j} f_{ij}(z_{ij} - \bar{z})^2 \\ &= \sum_{i,j} f_{ij}((ax_i + by_j) - (a\bar{x} + b\bar{y}))^2 \\ &= \sum_{i,j} f_{ij}(a(x_i - \bar{x}) + b(y_j - \bar{y}))^2 \\ &= a^2 \sum_{i,j} f_{ij}(x_i - \bar{x})^2 + 2ab \sum_{i,j} f_{ij}(x_i - \bar{x})(y_j - \bar{y}) + b^2 \sum_{i,j} f_{ij}(y_j - \bar{y})^2 \\ &= a^2 \text{Var}(X) + 2ab \text{Cov}(X, Y) + b^2 \text{Var}(Y), \end{aligned} \quad \square$$

La covariance permet de quantifier la dépendance de  $X$  et  $Y$  dans le sens suivant :

**Théorème 4.1.** Si les variables  $X$  et  $Y$  sont indépendantes, alors  $\text{Cov}(X, Y) = 0$ .

*Démonstration.* On reprend l'écriture de la covariance du point 1. de la proposition 4.3, que l'on combine avec les expressions des moyennes marginales :

$$\begin{aligned} \text{Cov}(X, Y) &= \left( \sum_{i,j} f_{ij} x_i y_j \right) - \bar{x} \bar{y} = \left( \sum_{i,j} f_{ij} x_i y_j \right) - \left( \sum_{i=1}^p f_{i \cdot} x_i \right) \left( \sum_{j=1}^q f_{\cdot j} y_j \right) \\ &= \left( \sum_{i,j} f_{ij} x_i y_j \right) - \left( \sum_{i,j} f_{i \cdot} f_{\cdot j} x_i y_j \right) = \sum_{i,j} (f_{ij} - f_{i \cdot} f_{\cdot j}) x_i y_j. \end{aligned}$$

Or, par définition, si  $X$  et  $Y$  sont indépendantes, pour tout  $i \in \{1, \dots, p\}$ ,  $j \in \{1, \dots, q\}$ , on a  $f_{ij} = f_{i.}f_{.j}$ ; d'où  $\text{Cov}(X, Y) = 0$ .  $\square$

**Corollaire 4.2.** *Si les variables  $X$  et  $Y$  sont indépendantes, alors :*

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

#### 4.3.4 COEFFICIENT DE CORRÉLATION

**Théorème 4.3** (Inégalité de Cauchy-Schwarz). *Soient  $X, Y$  des variables discrètes ou continue regroupées en classes. On a l'inégalité suivante :*

$$[\text{Cov}(X, Y)]^2 \leq \text{Var}(X) \text{Var}(Y) \quad \text{ou de façon équivalente} \quad |\text{Cov}(X, Y)| \leq \sigma_X \sigma_Y. \quad (4.2)$$

De plus, si les variables  $X$  et  $Y$  ne sont pas constantes, alors l'égalité dans l'équation (4.2) a lieu si et seulement si :

$$Y = \epsilon \frac{\sigma_Y}{\sigma_X} X + b \quad \text{avec} \quad \epsilon \in \{-1, 1\} \text{ et } b \in \mathbb{R}.$$

*Démonstration.* On considère la variable  $\lambda X + Y$  où  $\lambda \in \mathbb{R}$ . On a donc d'après le point 3. de la proposition 4.3 :

$$\text{Var}(\lambda X + Y) = \lambda^2 \text{Var}(X) + \lambda(2 \text{Cov}(X, Y)) + \text{Var}(Y),$$

que l'on voit comme un trinôme du second degré en  $\lambda$  de discriminant :

$$[2 \text{Cov}(X, Y)]^2 - 4 \text{Var}(X) \text{Var}(Y) = 4[\text{Cov}(X, Y)]^2 - 4 \text{Var}(X) \text{Var}(Y).$$

De plus, comme  $\text{Var}(\lambda X + Y) \geq 0$ , on sait que ce discriminant est négatif, d'où :

$$\begin{aligned} [\text{Cov}(X, Y)]^2 - \text{Var}(X) \text{Var}(Y) &\leq 0 \iff [\text{Cov}(X, Y)]^2 \leq \text{Var}(X) \text{Var}(Y) \\ &\iff |\text{Cov}(X, Y)| \leq \sigma_X \sigma_Y, \end{aligned}$$

ce qui montre la première partie. De plus, l'égalité dans l'équation (4.2) signifie d'une part que  $\text{Cov}(X, Y) = \epsilon \sigma_X \sigma_Y$  pour un certain  $\epsilon \in \{-1, 1\}$  et d'autre part que le discriminant est nul, donc que le polynôme admet une (unique, car  $X$  et  $Y$  ne sont pas constantes) racine :

$$\lambda_0 = -\frac{2 \text{Cov}(X, Y)}{2 \text{Var}(X)} = -\epsilon \frac{\sigma_Y}{\sigma_X}.$$

Mais alors, la variable  $\lambda_0 X + Y$  est de variance nulle, donc constante de valeur notée  $b \in \mathbb{R}$ , d'après le théorème 3.1.  $\square$

**Définition 4.10.** Lorsque les variables  $X$  et  $Y$  ne sont pas constantes, le *coefficient de corrélation* de  $X$  et  $Y$ , noté  $r(X, Y)$ , est le quotient de la covariance de  $X$  et  $Y$  par le produit des écarts-type de  $X$  et  $Y$  :

$$r(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$



**Corollaire 4.4** (du théorème 4.3). *Le coefficient de corrélation de  $X$  et  $Y$  vérifie :*

$$-1 \leq r(X, Y) \leq 1.$$

*De plus, on a  $|r(X, Y)| = 1$  si et seulement si  $X$  et  $Y$  vérifient une relation affine de la forme  $Y = aX + b$ , avec  $b \in \mathbb{R}$  et :*

$$r(X, Y) = 1 \iff a = \frac{\sigma_Y}{\sigma_X} > 0 \quad \text{et} \quad r(X, Y) = -1 \iff a = -\frac{\sigma_Y}{\sigma_X} < 0.$$

*Remarque.* Lorsque le coefficient de corrélation est « proche » de 1 en valeur absolue – prenons  $|r(X, Y)| \geq 0,9$  pour fixer les idées –, cela signifie qu’il y a une *liaison affine* importante entre les variables  $X$  et  $Y$  ; cette liaison étant exacte lorsque  $|r(X, Y)| = 1$ . En revanche, lorsque le coefficient de corrélation est proche de 0, alors il n’existe pas de relation affine entre  $X$  et  $Y$ , ce qui ne signifie pas qu’un autre type de liaison ne peut avoir lieu.

#### 4.4 AJUSTEMENT AFFINE

On suppose ici qu’il y a une liaison affine importante entre  $X$  et  $Y$ . Le principe d’un *ajustement affine*, aussi appelé *régression linéaire*, est de déterminer la « meilleure » droite pour exprimer la liaison affine entre  $X$  et  $Y$ , c’est-à-dire la droite qui approxime au mieux le nuage de points  $\mathcal{N}(\mathcal{P})$ .

*Remarque.* Dans les cas où la liaison entre  $X$  et  $Y$  est « indirectement » affine, c’est-à-dire de la forme  $Y = af(X) + b$ , on détermine dans un premier temps la fonction  $f$ . On étudie ensuite la variable  $Z = f(X)$  et l’on effectue une régression linéaire sur le couple  $(Z, Y)$ . C’est une *régression linéaire après changement de variable*.

##### 4.4.1 MÉTHODE DES MOINDRES CARRÉS

Pour tous  $a, b \in \mathbb{R}$ , on considère la variable  $\Delta_{(a,b)} = Y - (aX + b)$ . Cette variable contient l’information sur l’erreur commise si l’on modélise  $Y$  à partir de  $X$  par le changement de variable affine  $aX + b$ . On calcule la moyenne et la variance de  $\Delta_{(a,b)}$  :

$$\begin{aligned} \overline{\Delta_{(a,b)}} &= \bar{y} - (a\bar{x} + b) \quad \text{et} \\ \text{Var}(\Delta_{(a,b)}) &= \text{Var}(Y - (aX + b)) \\ &= \text{Var}(Y) - 2\text{Cov}(Y, aX + b) + \text{Var}(aX + b) \\ &= \text{Var}(Y) - 2a\text{Cov}(X, Y) + a^2\text{Var}(X). \end{aligned}$$

La *méthode des moindres carrés* consiste à déterminer  $a, b \in \mathbb{R}$  de telle sorte que  $\Delta_{(a,b)}$  soit le plus proche de la variable nulle, ce qui revient à minimiser  $|\overline{\Delta_{(a,b)}}|$  et  $\text{Var}(\Delta_{(a,b)})$ .

**Proposition 4.4** (Méthode des moindres carrés). *Si  $X$  n’est pas constante, la droite de régression par la méthode des moindres carrés de  $Y$  en fonction de  $X$  est la droite d’équation  $y = \hat{a}x + \hat{b}$  dans le repère du nuage de points de  $(X, Y)$  avec :*

$$\hat{a} = r(X, Y) \frac{\sigma_Y}{\sigma_X} \quad \text{et} \quad \hat{b} = \bar{y} - r(X, Y) \frac{\sigma_Y}{\sigma_X} \bar{x}.$$

*Démonstration.* Comme  $\text{Var}(\Delta_{(a,b)})$  est un trinôme du second degré en  $a$  de discriminant négatif (car la variance est toujours positive), il existe une unique valeur  $\hat{a}$  de  $a$  minimisant  $\text{Var}(\Delta_{(a,b)})$  :

$$\hat{a} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = r(X, Y) \frac{\sigma_Y}{\sigma_X}.$$

On peut alors fixer  $b$  pour annuler la moyenne :

$$\hat{b} = \bar{y} - \hat{a}\bar{x} = \bar{y} - r(X, Y) \frac{\sigma_Y}{\sigma_X} \bar{x}. \quad \square$$

*Remarque.*

1. La droite de régression obtenue par la méthode des moindres carrés passe par le barycentre  $(\bar{x}, \bar{y})$  du nuage de points  $\mathcal{N}(\mathcal{P})$ .
2. En prenant  $\overline{\Delta_{(a,b)}} = 0$ , on obtient :

$$\text{Var}(\Delta_{(a,b)}) = \frac{1}{N} \sum_{u=1}^N (\Delta_{(a,b)}(u))^2 = \frac{1}{N} \sum_{u=1}^N (Y(u) - (aX(u) + b))^2,$$

qui est  $\frac{1}{N}$  fois la somme des distances au carré entre les points  $(X(u), Y(u))$  du nuage et les points  $(X(u), aX(u) + b)$  de la droite. Ceci explique le nom de méthode des moindres carrés.

#### 4.4.2 MÉTHODE DE MAYER

Cette méthode d'ajustement est plus simple à mettre en place. Elle consiste, après avoir rangé les couples  $\{(X(u), Y(u))\}_{u \in \mathcal{P}}$  selon l'ordre croissant des  $\{X(u)\}_{u \in \mathcal{P}}$ , à fractionner la série statistique en deux séries dont les effectifs sont égaux (pour un nombre pair de points) ou différents de 1 (pour un nombre impair de points). On calcule pour chacune de ces deux parties les coordonnées de leurs points moyens  $G_1 = (\bar{x}_1, \bar{y}_1)$  et  $G_2 = (\bar{x}_2, \bar{y}_2)$ . On trace enfin la droite  $(G_1 G_2)$ .

Pour trouver l'équation de la droite obtenue, on utilise le fait qu'elle passe par les points  $G_1$  et  $G_2$  afin d'obtenir :

$$\bar{y}_1 = a\bar{x}_1 + b \quad \text{et} \quad \bar{y}_2 = a\bar{x}_2 + b.$$

Ce qui donne

$$a = \frac{\bar{y}_1 - \bar{y}_2}{\bar{x}_1 - \bar{x}_2} \quad \text{et} \quad b = \bar{y}_1 - \frac{\bar{y}_1 - \bar{y}_2}{\bar{x}_1 - \bar{x}_2} \bar{x}_1 = \frac{\bar{x}_1 \bar{y}_2 - \bar{y}_1 \bar{x}_2}{\bar{x}_1 - \bar{x}_2}.$$

**Proposition 4.5** (Méthode de Mayer). *Après avoir classé la série statistique  $(X, Y)$  par ordre croissant des  $x_i$ , on la divise en deux sous-séries  $(X_1, Y_1)$  et  $(X_2, Y_2)$  de même effectif (ou différents de 1). On désigne par  $\bar{x}_1, \bar{y}_1, \bar{x}_2$  et  $\bar{y}_2$  les moyennes de  $X_1, Y_1, X_2$  et  $Y_2$  respectivement. La droite de régression par la méthode de Mayer de  $Y$  en fonction de  $X$  est la droite d'équation  $y = \tilde{a}x + \tilde{b}$  avec :*

$$\tilde{a} = \frac{\bar{y}_1 - \bar{y}_2}{\bar{x}_1 - \bar{x}_2} \quad \text{et} \quad \tilde{b} = \frac{\bar{x}_1 \bar{y}_2 - \bar{y}_1 \bar{x}_2}{\bar{x}_1 - \bar{x}_2}.$$

**PRÉVISIONS**

A l'aide de l'équation  $y = ax + b$  de la droite obtenu par la méthode des moindres carrés ou par la méthode de Mayer, il est possible d'estimer la valeur que prendrait la variable  $X$  (respectivement  $Y$ ) pour une valeur de  $Y$  donnée (respectivement  $X$ ).

Pour une valeur  $x_0$  de la variable  $X$  qui ne fait pas partie des observations, on peut faire une prédiction de la valeur correspondante de  $Y$  en calculant l'ordonnée du point d'abscisse  $x_0$  en prenant  $y_0 = ax_0 + b$ .

Pour une valeur  $y_0$  de la variable  $Y$  qui ne fait pas partie des observations, on peut faire une prédiction de la valeur correspondante de  $X$  en calculant l'antécédent du point d'ordonnée  $y_0$  en prenant  $x_0 = \frac{y_0 - b}{a}$ .

**4.4.3 UN EXEMPLE**

On s'intéresse au lien éventuel entre le nombre d'heures d'ensoleillement et la température du mois de juillet dans plusieurs villes de France.

Ville	Température moyenne en juillet ( $X$ )	Ensoleillement, en heures par an ( $Y$ )
Ajaccio	22.2	2726
Bordeaux	20.8	1992
Clermont-Ferrand	19.7	1898
Brest	16.6	1492
Lille	17.9	1617
Lyon	21.3	2010
Millau	19.3	2121
Nice	23.1	2668
Paris	20	1630
Strasbourg	19.5	1633
Toulouse	21.6	2010
Fort-de-France	27.5	2437
Papeete	25	2685

On obtient directement :

$$\bar{x} = 21.1, \quad \bar{y} = 2071, \quad \text{Var}(X) = 7.8, \quad \text{Var}(Y) = 174629, \quad \sigma_X = 2.8, \quad \sigma_Y = 418.$$

On calcule ensuite la covariance :

$$\text{Cov}(X, Y) = \left( 22.2 \times 2726 + 20.8 \times 1992 + 19.7 \times 1898 + \dots + 25 \times 2685 \right) - 21.1 \times 2071 = 925.3,$$

d'où le coefficient de corrélation suivant :


$$r(X, Y) = \frac{925.3}{2.8 \times 418} = 0.79.$$

Bien que le coefficient de corrélation ne soit pas supérieur à 0.9, il en est proche et on va donc effectuer un ajustement affine.

Commençons par utiliser la méthode des moindres carrés : les coefficients de la droite sont donnés par :

$$\hat{a} = 0.79 \times \frac{418}{2.8} = 118.84 \quad \text{et} \quad \hat{b} = \bar{y} - \hat{a}\bar{x} = 2071 - 118.84 \times 21.1 = -438.73.$$

On obtient le graphique suivant :



Pour la méthode de Mayer, on commence par classer les données par ordre croissant en  $X$  :

$$(16.6, 1492), (17.9, 1617), (19.3, 2121), \dots, (25, 2685), (27.5, 2437).$$

On découpe ensuite la série en deux sous-séries de même taille (on a une taille impaire ici, on choisit donc (arbitrairement) de prendre un individu de plus dans la première sous-série). On obtient ainsi :


$$S_1 = \{(16.6, 1492), (17.9, 1617), (19.3, 2121), (19.5, 1633), (19.7, 1898), (20, 1630), (20.8, 1992)\},$$

$$S_2 = \{(21.3, 2010), (21.6, 2010), (22.2, 2726), (23.1, 2668), (25, 2685), (27.5, 2437)\}.$$

Pour tracer la droite de régression en utilisant la méthode de Mayer, il nous reste à déterminer les moyennes de chaque sous-série afin d'obtenir les coordonnées des deux points moyens :

$$G_1 = (\bar{x}_1, \bar{y}_1) = (19.1, 1769) \quad \text{et} \quad G_2 = (23.5, 2423).$$

On obtient le graphique suivant :





Deuxième partie

Probabilités



## CHAPITRE 5

# MODÉLISATION DES PHÉNOMÈNES ALÉATOIRES

### 5.1 INTRODUCTION

Une *expérience (ou phénomène) aléatoire* consiste en une expérience pour laquelle toutes les issues possibles sont connues, mais où interviennent de nombreux facteurs, dont nous ne connaissons ou maîtrisons qu'une petite partie. Dans ce cas, l'issue n'est pas prévisible avec certitude. La *théorie des probabilités* consiste en l'étude de ces expériences aléatoires.

Citons quelques exemples : le résultat d'un jeu de hasard (pile ou face, jet de dé, roulette etc.) ; durée de vie d'un atome radioactif, d'un individu, d'une ampoule ; les instants de passage d'un bus à un arrêt donné ; la promenade d'un ivrogne dans la rue ; la trajectoire d'une poussière à la surface de l'eau etc.

Les applications de la théorie des probabilités sont nombreuses : base de la statistique, outil puissant en finance, dans les assurances, théorie des jeux. Elle permet également de modéliser de nombreux phénomènes complexes en biologie, médecine, sciences humaines, climatologie. Elle s'est aussi révélée utile dans de nombreux domaines des mathématiques pures. Mais surtout, elle a acquis une place importante au sein des mathématiques en tant que discipline à part entière, de part son intérêt intrinsèque.

Historiquement, les jeux des hasards sont présents en Égypte, en Grèce et à Rome dès l'Antiquité. Il est cependant intéressant de constater qu'un traitement systématique n'est apparu qu'au XVI<sup>e</sup> siècle dans le livre *Liber de Ludo Alea* de Gerolamo Cardano (1501-1576). La véritable étincelle se trouve dans la correspondance entre Blaise Pascal (1623-1662) et Pierre de Fermat (~1605-1665), au sujet de problèmes posés par le chevalier de Méré. Encouragé par Pascal, Christian Huygens (1629-1695) publie *De ratiocinis in ludo aleae* (raisonnements sur les jeux de dés) en 1657. Ce livre est le premier ouvrage important sur les probabilités. Il y définit la notion d'espérance et y développe plusieurs problèmes de partages de gains lors de jeux ou de tirages dans des urnes. Deux ouvrages fondateurs sont également à noter : *Ars Conjectandi* de Jacques Bernoulli (1654-1705) qui définit la notion de variable aléatoire et donne la première version de la loi des grands nombres, et *The Doctrine of Chance* d'Abraham de Moivre (1668-1754) qui généralise l'usage de la combinatoire. On mentionnera également Pierre-Simon de Laplace (1749-1827), Leonhard Euler (1707-1783) et Johann Carl Friedrich Gauss (1777-1855).

La théorie des probabilités classique ne prend réellement son essor qu'avec les notions de mesure et d'ensembles mesurables qu'Émile Borel (1871-1956) introduit en 1897. Cette notion de mesure



est complétée par Henri Léon Lebesgue (1875-1941) et sa théorie de l'intégration. La première version moderne du théorème central limite est donnée par Alexandre Liapounov en 1901 et la première preuve du théorème moderne est due à Paul Lévy en 1910. Il faudra attendre 1933 pour que la théorie des probabilités sorte d'un ensemble de méthodes et d'exemples divers et devienne une véritable théorie, axiomatisée par Andreï Nikolaïevitch Kolmogorov (1903-1987).

## 5.2 L'ESPACE PROBABILISÉ $(\Omega, \mathcal{A}, \mathbb{P})$

Le but de la théorie des probabilités est de fournir un modèle mathématique pour décrire les expériences aléatoires. Sous sa forme moderne, la formulation de cette théorie contient trois ingrédients : l'*espace des états*, les *événements*, et la *loi de probabilité* ou simplement la *probabilité*. Dans toute la suite, nous considérons une expérience aléatoire que nous cherchons à modéliser.

### 5.2.1 ESPACE DES ÉTATS

**Définition.** L'*espace des états* appelé aussi *univers*, noté  $\Omega$ , est l'ensemble des résultats possibles de l'expérience.

*Exemple 5.1.* Voici quelques exemples de choix d'univers.

1. Lancer d'une pièce de monnaie.  $\Omega = \{P, F\}$ .
2. Deux lancers successifs d'une même pièce de monnaie.  $\Omega = \{PP, PF, FP, FF\}$ .
3. Lancer d'un dé.  $\Omega = \{1, 2, 3, 4, 5, 6\}$ .
4. Deux lancers successifs d'un même dé, et on s'intéresse à la somme des nombres obtenus. Dans ce cas, il y a trois choix raisonnables :

$$\begin{aligned}\Omega_1 &= \{(i, j) : i \in \{1, \dots, 6\}, j \in \{1, \dots, 6\}\} = \{1, \dots, 6\}^2, \\ \Omega_2 &= \{2, 3, 4, \dots, 12\}, \\ \Omega_3 &= \{(i, j) : i \in \{1, \dots, 6\}, j \in \{1, \dots, 6\}, i \leq j\}.\end{aligned}$$

5. Lancer d'un même dé indéfiniment.

$$\Omega = \{(u_n)_{n \geq 1} : \forall n \in \mathbb{N}^*, u_n \in \{1, \dots, 6\}\} = \{1, \dots, 6\}^{\mathbb{N}^*}.$$

6. Durée de vie d'un individu.  $\Omega = \{x \in \mathbb{R}^+ : 0 \leq x \leq 120\}$ .
7. Promenade d'un ivrogne dans une rue (un pas en avant, un pas en arrière).

$$\Omega = \{(u_n)_{n \geq 1} : \forall n \in \mathbb{N}^*, u_n \in \{-1, 1\}\} = \{-1, 1\}^{\mathbb{N}^*}.$$

8. Trajectoire d'une poussière à la surface de l'eau pendant un intervalle de temps  $[0, T]$ .  $\Omega = C([0, T]; \mathbb{R}^2)$ .

### 5.2.2 ÉVÉNEMENTS

**Définition 5.1.** Un *événement* est une propriété dont on peut dire si elle est réalisée ou non, une fois l'issue de l'expérience connue. Un événement correspond un sous-ensemble  $A$  de l'univers  $\Omega$ .

Un singleton, c'est-à-dire un événement réduit à un seul élément de  $\Omega$ , est appelé un *événement élémentaire*, sinon on parle d'*événement composite*.

*Exemple 5.2.* On reprend la numérotation de l'exemple 5.1. Voici quelques exemples d'événements écrits d'abord en mots, puis en tant que sous-ensembles de l'espace des états  $\Omega$ .

2. "Le premier jet donne pile" est le sous-ensemble  $\{PP, PF\}$  de  $\Omega$ .
4. "La somme des résultats obtenus est égale à 4" est le sous-ensemble  $\{(1, 3), (2, 2), (3, 1)\}$  de  $\Omega_1$ , au sous-ensemble  $\{4\}$  de  $\Omega_2$ , et au sous-ensemble  $\{\{1, 3\}, \{2, 2\}\}$  de  $\Omega_3$ .
5. "Le premier 1 est obtenu au  $N$ -ième lancer" est le sous-ensemble

$$\{(u_n)_{n \geq 1} \in \Omega : u_1 \geq 2, \dots, u_{N-1} \geq 2, u_N = 1\}.$$

6. "L'individu atteint au moins 50 ans" est le sous-ensemble :

$$\{x \in \mathbb{R}^+ : 50 \leq x \leq 120\}.$$

7. "L'ivrogne avance au  $N$ -ième pas" est le sous-ensemble :

$$\{(u_n)_{n \geq 1} \in \Omega : u_N = 1\}.$$

*Remarque.* Les événements, qui sont par définition des sous-ensembles de l'univers, sont en général décrits à l'aide de phrases dans un premier temps. En effet, on commence par se poser une question liée à une expérience aléatoire, puis on introduit un modèle probabiliste pour y répondre. Par exemple, on cherche la probabilité que la somme de deux dés lancés au hasard soit égale à 4 ; l'événement considéré est alors "la somme des dés est égale à 4".

Une fois fixé le choix de l'univers, un événement correspond à un *unique* sous-ensemble de ce dernier. Comme il n'y a pas forcément unicité du modèle et qu'alors les événements peuvent s'écrire en termes de sous-ensembles sous des formes différentes, la phrase qui décrit un événement permet de se comprendre, quel que soit le modèle choisi, voir par exemple les exemples 5.1 et 5.2 numéro 4. Remarquons aussi que, étant donné un sous-ensemble d'un univers, il est souvent possible de le décrire par différentes phrases, qui représentent toutes le même événement. Par exemple l'événement  $\{PP, PF\}$  de l'exemple 5.2 numéro 2 peut se traduire par "le premier jet donne pile" ou "le premier jet ne donne pas face".

Puisque les événements sont des sous-ensembles, on peut effectuer les opérations habituelles, avec la correspondance suivante entre les terminologies ensembliste et probabiliste.

Notation	Terminologie ensembliste	Terminologie probabiliste
$\Omega$	ensemble entier	espace des états, événement certain
$\omega$	élément de $\Omega$	événement élémentaire
$A$	sous-ensemble de $\Omega$	événement
$\omega \in A$	$\omega$ appartient à $A$	$A$ est réalisé si $\omega$ est le résultat de l'expérience
$A \subset B$	$A$ est inclu dans $B$	si $A$ est réalisé alors $B$ aussi
$A \cup B$	réunion de $A$ et $B$	l'événement " $A$ ou $B$ " (ou non exclusif!)
$A \cap B$	intersection de $A$ et $B$	l'événement " $A$ et $B$ "
$A^c$	complémentaire de $A$	l'événement contraire de $A$
$\emptyset$	ensemble vide	événement impossible
$A \cap B = \emptyset$	$A$ et $B$ sont disjoints	$A$ et $B$ sont incompatibles

*Exemple.* Deux lancers successifs d'une même pièce de monnaie. Soient  $A = \{PP\}$ ,  $B = \{PF\}$ ,  $C = \{FP, FF\}$ . Alors,

- $A \cup B = \{PP, PF\} = C^c$ , est l'événement "le premier jet donne pile";
- $A \cap B = \emptyset$ , est l'événement impossible,  $A$  et  $B$  sont incompatibles.

**Propriété 5.1.** Les opérations sur les événements satisfont aux règles suivantes. Pour tout événements  $A, B, C$ , on a

- *commutativité* :  $A \cup B = B \cup A$ ;
- *associativité* :  $(A \cup B) \cup C = A \cup (B \cup C)$ ;
- *distributivité* :  $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$ ;
- *lois de De Morgan* :  $(A \cup B)^c = A^c \cap B^c$ , et  $(A \cap B)^c = (A^c \cup B^c)$ .

Un événement est donc un sous-ensemble des parties de  $\Omega$ ,  $\mathcal{P}(\Omega)$ . Comme ensemble des événements il semblerait donc naturel de prendre tout  $\mathcal{P}(\Omega)$ . C'est ce que l'on va faire lorsque  $\Omega$  est *fini* ou *dénombrable*. Cependant, il existe des exemples d'univers où il est impossible d'associer à chaque événement une probabilité de façon cohérente. Dans ces cas-là, il est donc nécessaire de se restreindre à un sous-ensemble strict de  $\mathcal{P}(\Omega)$  contenant les événements "intéressants". Ils devront satisfaire à quelques propriétés naturelles : ils doivent former une *tribu*. Nous ne donnons pas cette définition car elle est hors-programme.

Finalement, nous notons  $\mathcal{A}$  l'ensemble des événements. Si  $\Omega$  est fini ou dénombrable,  $\mathcal{A} = \mathcal{P}(\Omega)$ ; sinon  $\mathcal{A}$  peut-être strictement inclus dans  $\mathcal{P}(\Omega)$ .

### 5.2.3 PROBABILITÉ

Nous souhaitons maintenant associer à chacun des événements une *probabilité*, qui mesure la vraisemblance que l'on accorde a priori à l'événement avant la réalisation de l'expérience. C'est une des données du modèle, que l'on peut comprendre intuitivement de différentes manières, en voici deux.

*Approche utilisant les symétries.* On considère un dé non-pipé. Il est alors naturel de supposer que chacune des issues possibles ait la même probabilité égale à  $1/6$ . Il faut cependant être prudent avec cette approche. En effet, supposons que nous souhaitions déterminer la probabilité du sexe

d'un nouveau né. Il n'y a aucune raison de penser qu'il y a plus de chances d'avoir un garçon ou une fille, de sorte qu'il est naturel d'associer une probabilité  $1/2$  à chacun des événements élémentaires. Cependant, les statistiques montrent que la proportion de garçons nouvellement né est de  $51,2\%$  (INED, France métropolitaine).

*Approche fréquentiste.* On suppose qu'une expérience d'univers  $\Omega$  est exécutée plusieurs fois sous les mêmes conditions. Pour chaque événement  $A$  de  $\Omega$ , on définit  $n_N(A)$  comme le nombre de fois où l'événement  $A$  survient lors des  $N$  premières répétitions de l'expérience. Alors la *probabilité de l'événement  $A$* , notée  $\mathbb{P}(A)$ , est définie comme la limite, dans un sens à préciser, du quotient  $n_N(A)/N$ .

Cela veut dire que  $\mathbb{P}(A)$  est définie comme la limite du pourcentage du nombre de fois où  $A$  survient par rapport au nombre total des répétitions. C'est donc la fréquence limite de  $A$ . Bien que cette définition soit intuitivement commode, elle présente un sérieux inconvénient. En effet, il faut justifier de l'existence de la limite, ce qui est difficile a priori.

Il est plus raisonnable d'admettre que les probabilités satisfont à un ensemble d'axiomes simples et intuitivement acceptables, pour ensuite démontrer qu'une telle fréquence limite existe dans un certain sens (il s'agit de la *loi des grands nombres*).

**Définition.** Étant donné un espace d'états  $\Omega$  et  $\mathcal{A}$  l'ensemble des événements, une *probabilité  $\mathbb{P}$  sur  $(\Omega, \mathcal{A})$* , est une application de  $\mathcal{A}$  dans  $[0, 1]$ , possédant les propriétés suivantes.

1. L'événement certain est de probabilité 1 :  $\mathbb{P}(\Omega) = 1$ .
2. *Axiome de  $\sigma$ -additivité* : pour toute famille dénombrable  $(A_n)_{n \geq 0}$  d'événements de  $\mathcal{A}$ , deux-à-deux disjoints, on a

$$\mathbb{P}\left(\bigcup_{n \geq 0} A_n\right) = \sum_{n=0}^{+\infty} \mathbb{P}(A_n).$$

Le triplet  $(\Omega, \mathcal{A}, \mathbb{P})$  est alors appelé un *espace probabilisé*.

On a les conséquences immédiates suivantes.

**Proposition 5.1.** Soit  $(\Omega, \mathcal{A}, \mathbb{P})$  un espace probabilisé et soient deux événements  $A \in \mathcal{A}$ ,  $B \in \mathcal{A}$ .

1. Additivité. Si  $A$  et  $B$  sont disjoints, alors  $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$ . En particulier,  $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ , et  $\mathbb{P}(\emptyset) = 0$ .
2. Si  $A \subset B$ , alors :  $\mathbb{P}(A) \leq \mathbb{P}(B)$ .
3.  $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$ .
4. Plus généralement, on a la formule de Poincaré : Soit  $(A_n)_{n=1}^N$  une famille d'événements de  $\mathcal{A}$ , alors :

$$\mathbb{P}\left(\bigcup_{n=1}^N A_n\right) = \sum_{n=1}^N (-1)^{n-1} \sum_{\substack{J \subset \{1, \dots, N\} \\ \text{card}(J) = n}} \mathbb{P}\left(\bigcap_{k \in J} A_k\right).$$



# CHAPITRE 6

## CONSTRUCTION D'ESPACES PROBABILISÉS

On suppose dans la suite que l'univers  $\Omega$  est fini ou dénombrable. L'ensemble des événements est donc  $\mathcal{P}(\Omega)$ .

### 6.1 CARACTÉRISATION D'UNE PROBABILITÉ

Avec la définition de probabilité du chapitre précédent, il n'est pas si aisé de définir concrètement une probabilité. Dans le cas où  $\Omega$  est fini ou dénombrable, on dispose de la caractérisation suivante.

**Proposition 6.1.** *Une probabilité sur  $(\Omega, \mathcal{P}(\Omega))$  est caractérisée par sa valeur sur les singletons  $\{\omega\}$ , pour tout  $\omega \in \Omega$ . Réciproquement, à toute famille  $(p_\omega)_{\omega \in \Omega}$  telle que :*

1. *pour tout  $\omega \in \Omega$ ,  $0 \leq p_\omega \leq 1$ ,*
2.  *$\sum_{\omega \in \Omega} p_\omega = 1$ ,*

*on peut associer une unique probabilité  $\mathbb{P}$  sur  $(\Omega, \mathcal{P}(\Omega))$  définie par :  $\mathbb{P}(\{\omega\}) = p_\omega$ . On étend ensuite  $\mathbb{P}$  à  $\mathcal{P}(\Omega)$  par  $\sigma$ -additivité : pour tout  $A \in \mathcal{P}(\Omega)$ ,*

$$\mathbb{P}(A) = \sum_{\omega \in A} p_\omega.$$

### 6.2 CAS OÙ L'UNIVERS EST FINI

Un exemple particulier et très classique de choix de probabilité nous amène à toutes les questions de dénombrements.

**Définition.** Une probabilité  $\mathbb{P}$  sur  $(\Omega, \mathcal{A})$  est dite *uniforme*, si  $\mathbb{P}(\{\omega\})$  ne dépend pas de  $\omega \in \Omega$ . On dit alors que l'on est en situation d'*équiprobabilité*.

**Corollaire 6.1.** *Dans ce cas, pour tout  $\omega \in \Omega$ ,  $\mathbb{P}(\{\omega\}) = \frac{1}{\text{card}(\Omega)}$ , et, pour tout événement  $A \in \mathcal{P}(\Omega)$ , on a :*

$$\mathbb{P}(A) = \frac{\text{card}(A)}{\text{card}(\Omega)}.$$

*Exemple.* Reprenons la question 4 des exemples 5.1 et 5.2 du Chapitre 5 et calculons la probabilité de l'événement  $A$  “la somme des dés est égale à 4”.

Supposons que l'on ait choisi l'espace  $\Omega_1$ . Alors, on est en situation d'équiprobabilité et la probabilité  $\mathbb{P}_1$  sur  $\Omega_1$  est uniforme, de sorte que pour tout  $(i, j) \in \{1, \dots, 6\}^2$  :

$$\mathbb{P}_1[\{(i, j)\}] = \frac{1}{36}.$$

Ainsi,  $\mathbb{P}_1(A) = \mathbb{P}_1[\{(1, 3), (2, 2), (3, 1)\}] = \frac{\text{card}(A)}{\text{card}(\Omega_1)} = \frac{3}{36}$ .

Supposons maintenant que l'on ait choisi l'espace  $\Omega_2$ . Alors, on n'est plus en situation d'équiprobabilité. Au vu des conditions de l'expérience, on définit  $\mathbb{P}_2$  ainsi :

$$\begin{aligned} \mathbb{P}_2(\{2\}) = \mathbb{P}_2(\{12\}) &= \frac{1}{36}, & \mathbb{P}_2(\{3\}) = \mathbb{P}_2(\{11\}) &= \frac{1}{18}, & \mathbb{P}_2(\{4\}) = \mathbb{P}_2(\{10\}) &= \frac{1}{12}, \\ \mathbb{P}_2(\{5\}) = \mathbb{P}_2(\{9\}) &= \frac{1}{9}, & \mathbb{P}_2(\{6\}) = \mathbb{P}_2(\{8\}) &= \frac{5}{36}, & \mathbb{P}_2(\{7\}) &= \frac{1}{6}. \end{aligned}$$

Ainsi,  $\mathbb{P}_2(A) = \mathbb{P}_2(\{4\}) = \frac{1}{12}$  mais  $\frac{\text{card}(A)}{\text{card}(\Omega_2)} = \frac{1}{11}$ , d'où  $\mathbb{P}_2(A) \neq \frac{\text{card}(A)}{\text{card}(\Omega_2)}$ .

Remarquer que s'il on avait choisi l'univers  $\Omega_3$ , on ne serait pas non plus en situation d'équiprobabilité.

Cet exemple montre qu'il est très important de spécifier le choix d'univers et de probabilité. Bien que les résultats finaux ne changent pas, les raisonnements pour y arriver sont différents et doivent être explicités.

Lorsque l'espace des états est fini, les calculs de probabilités se ramènent essentiellement à des problèmes de dénombrement, sujet de la section suivante.

### 6.2.1 DÉNOMBREMENT, MODÈLE D'URNE

**Définition.** Une *population* de taille  $N$  est un ensemble  $\mathcal{S} = \{s_1, \dots, s_N\}$  de  $N$  éléments. Les éléments de  $\mathcal{S}$  sont les *individus* de la population  $\mathcal{S}$ . La *taille*  $N$  est le nombre d'éléments de  $\mathcal{S}$ .

#### TIRAGES ORDONNÉS

Un *échantillon* de taille  $r$  est un  $r$ -uplet  $(s_{i_1}, \dots, s_{i_r})$  d'éléments de  $\mathcal{S}$ . Deux procédures sont possibles.

- *Le tirage avec remise.* Dans ce cas, chaque élément de l'ensemble peut être choisi à plusieurs reprises. On parle alors d'*échantillon de taille  $r$  avec répétitions*. Soit  $\Omega_1$  l'ensemble de ces échantillons, alors  $\Omega_1 = \{s_1, \dots, s_N\}^r$ , et :

$$\text{card}(\Omega_1) = N^r.$$

- *Le tirage sans remise.* Dans ce cas, chaque élément de l'ensemble peut être choisi au plus une fois. On parle alors d'*échantillon de taille  $r$  sans répétition*, ou d'*arrangement des éléments de  $\mathcal{S}$  pris  $r$  à  $r$* . Naturellement, on impose les conditions supplémentaires  $r \leq N$ , et  $\forall j \neq k, i_j \neq i_k$ . Soit  $\Omega_2$  l'ensemble de ces échantillons, on a alors :

$$\text{card}(\Omega_2) = N(N-1) \cdots (N-r+1) = \frac{N!}{(N-r)!}$$

Ce nombre a deux notations usuelles :  $A_N^r$  ou  $(N)_r$  (*symbole de Pochhammer*).

*Exemple.* On considère une population de taille  $N$  et un échantillon aléatoire de taille  $r$  avec répétition. On choisit alors comme univers  $\Omega_1$  que l'on munit de la probabilité uniforme, notée  $\mathbb{P}$ . On s'intéresse à l'événement  $A$  "aucun individu n'a été choisi plus d'une fois" qui est la même chose que "tous les individus sont distincts". Alors on a,  $A = \Omega_2$  et :

$$\mathbb{P}(A) = \frac{\text{card}(\Omega_2)}{\text{card}(\Omega_1)} = \frac{A_N^r}{N^r}.$$

Donnons quelques applications de ce résultat.

1. On jette un dé six fois de suite. Alors la probabilité d'obtenir six nombres distincts est  $\frac{6!}{6^6} \sim 0,015$ .
2. Supposons que dans une ville, il y ait sept accidents par semaine. Alors la probabilité d'avoir exactement un accident chaque jour de la semaine est  $\frac{7!}{7^7} \sim 0,00612$ .

#### TIRAGES NON ORDONNÉS

Une *sous-population* de taille  $r$  est un sous-ensemble  $\{s_{i_1}, \dots, s_{i_r}\}$  d'éléments de  $\mathcal{S}$ . De manière similaire aux tirages ordonnés, deux procédures sont possibles.

- *Le tirage sans remise.* On parle alors de *sous-population de taille  $r$  sans répétition*, ou de *combinaison de  $r$  éléments*. On impose à nouveau les conditions supplémentaires,  $r \leq N$ , et  $\forall j \neq k, i_j \neq i_k$ . Soit  $\Omega_3$  l'ensemble de ces populations, on a alors :

$$\text{card}(\Omega_3) = \frac{N!}{(N-r)!r!}.$$

Ce nombre, appelé *coefficient binomial*, a deux notations usuelles :  $C_N^r$  (notation qui n'est plus tellement en vigueur) ou  $\binom{N}{r}$ .

*Démonstration.* Chacun des sous-ensembles à  $r$  éléments fournit  $r!$  échantillons de taille  $r$  sans répétition, de sorte que  $\text{card}(\Omega_2) = r! \text{card}(\Omega_3)$ .  $\square$

*Exemple 6.1.*

1. On appelle main de poker l'ensemble des 5 cartes que chacun des quatre joueurs reçoit lors de la distribution d'un jeu qui en contient 32. Alors il existe  $\binom{32}{5}$  mains différentes. Soit  $A$  l'événement "les hauteurs des 5 cartes sont différentes", calculons  $\text{card}(A)$ . On peut choisir ces hauteurs de  $\binom{8}{5}$  manières différentes. Il faut ensuite choisir la couleur (trèfle, carreau, cœur, pique) de chacune des hauteurs. Ainsi :

$$\text{card}(A) = \binom{8}{5} 4^5.$$

Étant donné que toutes les mains sont supposées équiprobables, la probabilité d'obtenir une main dont les 5 cartes ont une hauteur différente est :

$$\mathbb{P}(A) = \frac{\binom{8}{5} 4^5}{\binom{32}{5}}.$$



2. Une urne contient  $N_b$  boules blanches et  $N_n$  boules noires. Posons  $N = N_b + N_n$ . On tire  $r$  boules avec remise dans l'urne, il y a alors  $N^r$  tirages possibles. Soit  $A_k$  l'événement "on a tiré exactement  $k$  boules blanches", calculons  $\text{card}(A_k)$ . L'événement  $A_k$  est réalisé lorsque l'issue est constituée de  $k$  boules blanches et  $r - k$  boules noires. Il y a  $\binom{r}{k}$  façons de choisir la position des boules blanches, la position des boules noires est ensuite fixée. Pour chacune des positions de boule blanche, il y a ensuite  $N_b$  choix de boules blanches possibles, et pour chacune des positions de boule noire, il y a  $N_n$  choix possibles, ainsi :

$$\text{card}(A_k) = \binom{r}{k} N_b^k N_n^{r-k}.$$

Étant donné que tous les tirages sont supposés équiprobables, la probabilité d'obtenir exactement  $k$  boules blanches lors d'un tirage de  $r$  boules avec remise est :

$$\mathbb{P}(A_k) = \frac{\binom{r}{k} N_b^k N_n^{r-k}}{N^r} = \binom{r}{k} \left(\frac{N_b}{N}\right)^k \left(\frac{N_n}{N}\right)^{r-k}.$$

Ceci est un exemple de la *loi binomiale*, que nous reverrons plus tard.

3. Soit  $\mathcal{S}$  une population de taille  $N$  (*ex.* des étudiants), que l'on range en deux catégories  $a$  et  $b$  incompatibles (*ex.* filles et garçons), de tailles respectives  $N_a$  et  $N_b = N - N_a$ . On choisit "au hasard" une sous-population de taille  $r$  sans répétition, il y a alors  $\binom{N}{r}$  choix possibles. Soit  $A_k$  l'événement "on a choisi exactement  $k$  individus de la catégorie  $a$ ", calculons  $\text{card}(A_k)$ . L'événement est réalisé lorsque l'issue est constituée de  $k$  individus de la catégorie  $a$  et  $r - k$  de la catégorie  $b$ . Il y a  $\binom{N_a}{k}$  façons de choisir les  $k$  individus de la catégorie  $a$  et pour chacune il y a  $\binom{N - N_a}{r - k}$  façons de choisir les individus restants dans la catégorie  $b$ , ainsi :

$$\text{card}(A_k) = \binom{N_a}{k} \binom{N - N_a}{r - k}.$$

Remarquer que pour que ceci ait un sens, il faut que  $0 \leq k \leq \min\{r, N_a\}$ . Étant donné que tous les tirages sont supposés équiprobables, la probabilité d'obtenir  $k$  individus de la catégorie  $a$  lors de ce tirage est :

$$\mathbb{P}(A_k) = \frac{\binom{N_a}{k} \binom{N_b}{r-k}}{\binom{N}{r}}.$$

Ceci est un exemple de la *loi hypergéométrique*.

*Remarque.* Supposons que  $N_a = N_a(N)$  soit une fonction de  $N$  et que le nombre total de boules tende vers l'infini, de sorte que la proportion  $\frac{N_a}{N}$  tende vers  $p$  (et donc que  $\frac{N_b}{N}$  tende vers  $1 - p$ ), avec  $0 < p < 1$ . Ainsi,  $N_a$  et  $N_b$  tendent vers  $+\infty$  avec  $N$ . Fixons  $r \geq 0$  et  $k$  compris entre 0 et  $r$ . Alors, pour  $N$  assez grand, on a  $N_a \geq k$ ,  $N_b \geq r - k$  et  $\mathbb{P}(A_k)$

peut s'écrire :

$$\begin{aligned}
\mathbb{P}(A_k) &= \frac{N_a(N_a-1)\dots(N_a-k+1)}{k!} \frac{N_b(N_b-1)\dots(N_b-r+k+1)}{(r-k)!} \frac{r!}{N(N-1)\dots(N-r+1)} \\
&= \frac{r!}{k!(r-k)!} \frac{N_a(N_a-1)\dots(N_a-k+1) N_b(N_b-1)\dots(N_b-r+k+1)}{N(N-1)\dots(N-r+1)} \\
&= \frac{r!}{k!(r-k)!} \frac{N^k \frac{N_a}{N} (\frac{N_a}{N} - \frac{1}{N}) \dots (\frac{N_a}{N} - \frac{k-1}{N}) N^{r-k} \frac{N_b}{N} (\frac{N_b}{N} - \frac{1}{N}) \dots (\frac{N_b}{N} - \frac{r-k-1}{N})}{N^r 1(1 - \frac{1}{N}) \dots (1 - \frac{r-1}{N})} \\
&= \binom{r}{k} \frac{\frac{N_a}{N} (\frac{N_a}{N} - \frac{1}{N}) \dots (\frac{N_a}{N} - \frac{k-1}{N}) \frac{N_b}{N} (\frac{N_b}{N} - \frac{1}{N}) \dots (\frac{N_b}{N} - \frac{r-k-1}{N})}{1(1 - \frac{1}{N}) \dots (1 - \frac{r-1}{N})} \\
&\xrightarrow{N \rightarrow +\infty} \frac{\binom{r}{k} p^k (1-p)^{r-k}}{1}.
\end{aligned}$$

Ainsi,  $\mathbb{P}(A_k)$  tend vers  $\binom{r}{k} p^k (1-p)^{r-k}$ . On a donc obtenu la loi binomiale comme limite de lois hypergéométriques. Ce résultat est intuitif, car lorsque le nombre de boules est très grand, que le tirage s'effectue avec ou sans remise ne change pas grand chose : on a peu de chance de tirer deux fois la même boule.

• *Partitionnement*

Soient  $r_1, \dots, r_k$  des entiers positifs (éventuellement nuls) tels que,  $r_1 + \dots + r_k = N$ . Le nombre de façons de répartir  $N$  objets dans  $k$  familles de sorte que la  $i$ -ième famille contienne  $r_i$  éléments est égal à :

$$\frac{N!}{r_1! \dots r_k!}.$$

Ce nombre se note  $\binom{N}{r_1 \dots r_k}$  et s'appelle *coefficient multinomial*.

*Démonstration.* Pour remplir la première famille, il faut choisir  $r_1$  objets parmi  $N$ , ce qui peut se faire de  $\binom{N}{r_1}$  façons. Pour remplir la seconde famille, il faut choisir  $r_2$  objets parmi  $N - r_1$ , soit  $\binom{N-r_1}{r_2}$ . En continuant ainsi, on obtient que le nombre de telles répartitions est de :

$$\binom{N}{r_1} \binom{N-r_1}{r_2} \dots \binom{N-r_1-\dots-r_{k-1}}{r_k} = \frac{N!}{r_1! \dots r_k!}.$$

□

*Exemple.* Le nombre d'anagrammes du mot CHERCHER est  $\frac{8!}{2!2!2!1!}$ .

• *Le tirage avec remise.* On parle alors de *sous-population de taille  $r$  avec répétitions*. Soit  $\Omega_4$  l'ensemble de ces populations, on a alors :

$$\text{card}(\Omega_4) = \binom{N+r-1}{N-1} = \binom{N+r-1}{r}.$$

*Démonstration.* Ce problème revient à placer  $r$  boules indistinguables dans  $N$  urnes. En effet, le nombre de boules dans la  $i$ -ième urne compte le nombre de répétitions de l'individu  $i$  lors du tirage. Représentons les  $r$  boules par  $r$  étoiles alignées, avec une cloison à chacune des extrémités. Par exemple, lorsque  $r = 7$ ,

$$| * * * * * * * |$$

Répartir les  $r$  boules dans  $N$  urnes revient à rajouter  $N - 1$  cloisons formant les  $N$  urnes. Par exemple, lorsque  $r = 7$ ,  $N = 3$ ,

$$| ** || * * * * * |,$$

représente le tirage :  $s_1, s_1, s_3, s_3, s_3, s_3, s_3$ . Ainsi, ce problème revient à placer  $N - 1$  cloisons sur  $N + r - 1$  positions, les positions restantes étant occupées par des  $*$ .

□

*Exemple.* Soient  $r \in \mathbb{N}^*$  et  $n \in \mathbb{N}^*$ . On cherche à compter le nombre de suites d'entiers naturels  $r_1, \dots, r_n$ , telles que :

$$r_1 + \dots + r_n = r.$$

Ce problème revient à placer  $r$  boules indistinguables dans  $n$  urnes, où le nombre de boules dans la  $i$ -ième urne représente  $r_i$ . Ainsi, le nombre de ces suites est  $\binom{n+r-1}{n-1}$ . Par exemple, si  $r = 10$ ,  $n = 3$ ,

$$| ** | * * * * * | * * * |$$

représente la partition  $(2, 5, 3)$  de 10. Remarquer que ces suites sont naturellement ordonnées de sorte que l'on distingue  $(2, 5, 3)$  de  $(5, 3, 2)$ .

### 6.3 ESPACE DES ÉTATS INFINI DÉNOMBRABLE

Lorsque  $\Omega$  est infini dénombrable, on procède de la même manière que dans le cas fini : on prend  $\mathcal{A} = \mathcal{P}(\Omega)$ , et on associe à chaque événement élémentaire  $\omega \in \Omega$ , sa probabilité,  $\mathbb{P}(\{\omega\}) = p_\omega \in [0, 1]$ , avec :

$$\sum_{\omega \in \Omega} p_\omega = 1.$$

*Exemple.* On jette une pièce de monnaie jusqu'à l'obtention du premier pile. On peut choisir  $\Omega = \mathbb{N}^* \cup \{\infty\}$  où, pour tout  $k \in \mathbb{N}^*$ ,  $\{k\}$  représente l'événement "le premier pile est obtenu au  $k$ -ième jet", et  $\{\infty\}$  représente l'événement "pile ne sort jamais". Si la pièce est équilibrée, on aura, pour tout  $k \in \mathbb{N}^*$  :

$$\mathbb{P}(\{k\}) = \frac{1}{2^k}.$$

Comme  $\mathbb{N}^*$  et  $\{\infty\}$  sont disjoints,  $1 = \mathbb{P}[\Omega] = \mathbb{P}[\{\infty\}] + \mathbb{P}[\bigcup_{k \in \mathbb{N}^*} \{k\}]$ . Ainsi, la probabilité que pile ne sorte jamais est donnée par :

$$\begin{aligned} \mathbb{P}(\{\infty\}) &= 1 - \mathbb{P}[\bigcup_{k \in \mathbb{N}^*} \{k\}] \\ &= 1 - \sum_{k=1}^{+\infty} \mathbb{P}[\{k\}], \text{ car les événements sont disjoints} \\ &= 1 - \sum_{k=1}^{+\infty} \frac{1}{2^k} = 0. \end{aligned}$$

La probabilité que le premier pile sorte après un nombre pair de lancers est :

$$\mathbb{P}(\{2, 4, 6, \dots\}) = \sum_{k=1}^{+\infty} \mathbb{P}(\{2k\}) = \sum_{k=1}^{+\infty} \frac{1}{2^{2k}} = \frac{1}{3}.$$

# CHAPITRE 7

## CONDITIONNEMENT ET INDÉPENDANCE

### 7.1 PROBABILITÉ CONDITIONNELLE

#### 7.1.1 DÉFINITION

Motivons la définition de probabilité conditionnelle sur un exemple.

Soit  $\Omega$  une population partitionnée en  $\Omega = S \cup S^c$ , où  $S$  représente l'ensemble des individus fumeurs. Soit  $F$  l'ensemble des femmes, de sorte que  $F \cup F^c$  représente une autre partition de  $\Omega$ . On suppose que l'on choisit un individu "au hasard", de sorte que l'on munit  $\Omega$  de la probabilité uniforme, notée  $\mathbb{P}$ . Ainsi, la probabilité que l'individu choisi soit fumeur est :

$$\mathbb{P}(S) = \frac{\text{card}(S)}{\text{card}(\Omega)}.$$

Si maintenant on choisit un individu avec l'information supplémentaire qu'il s'agit d'une femme, tout se passe comme si l'univers considéré est  $F$ , et que l'on a partitionné  $F$  (et non plus  $\Omega$ ) en  $S \cap F$  et  $S^c \cap F$ . Ainsi la probabilité que l'individu choisi soit fumeur, étant donné l'information que c'est une femme, est égale à :

$$\frac{\text{card}(S \cap F)}{\text{card}(F)} = \frac{\text{card}(S \cap F) / \text{card}(\Omega)}{\text{card}(F) / \text{card}(\Omega)},$$

quantité encore égale, avec les notations précédentes, à

$$\frac{\mathbb{P}(S \cap F)}{\mathbb{P}(F)}.$$

**Définition.** Soit  $(\Omega, \mathcal{A}, \mathbb{P})$  un espace probablisé, et  $B$  un événement tel que  $\mathbb{P}(B) > 0$ . Pour tout  $A \in \mathcal{A}$ , on définit la *probabilité conditionnelle de  $A$  sachant  $B$* , notée  $\mathbb{P}_B(A)$ , par :

$$\mathbb{P}_B(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \quad (7.1)$$

**Lemme 7.1.** *Sous les hypothèses de la définition ci-dessus, l'application  $\mathbb{P}_B$  est une probabilité sur  $(\Omega, \mathcal{A})$ , ainsi  $(\Omega, \mathcal{A}, \mathbb{P}_B)$  est un espace probablisé.*

*Démonstration.* Il faut montrer que  $\mathbb{P}_B$  satisfait aux trois axiomes caractérisant une probabilité.

- Par hypothèse,  $\mathbb{P}(B) > 0$ . De plus, pour tout  $A \in \mathcal{A}$ , on a  $A \cap B \subset B$ , d'où  $0 \leq \mathbb{P}(A \cap B) \leq \mathbb{P}(B)$ , et donc :

$$0 \leq \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \leq 1.$$

- Comme  $\Omega \cap B = B$ , on a  $\mathbb{P}_B(\Omega) = 1$ .
- Soit  $(A_n)_{n \geq 1}$  une famille dénombrable d'événements deux à deux disjoints. Alors on a l'égalité  $(\bigcup_{n \geq 1} A_n) \cap B = \bigcup_{n \geq 1} (A_n \cap B)$ . Comme les événements  $(A_n)_{n \geq 1}$  sont deux à deux disjoints, il en est de même pour les événements  $(A_n \cap B)_{n \geq 1}$ . Ainsi la  $\sigma$ -additivité de  $\mathbb{P}$  implique  $\mathbb{P}\left(\bigcup_{n \geq 1} (A_n \cap B)\right) = \sum_{n \geq 1} \mathbb{P}(A_n \cap B)$ , et on conclut :

$$\mathbb{P}_B\left(\bigcup_{n \geq 1} A_n\right) = \frac{\mathbb{P}\left(\left(\bigcup_{n \geq 1} A_n\right) \cap B\right)}{\mathbb{P}(B)} = \sum_{n \geq 1} \frac{\mathbb{P}(A_n \cap B)}{\mathbb{P}(B)} = \sum_{n \geq 1} \mathbb{P}_B(A_n).$$

□

*Remarque.*

- On utilise aussi la notation  $\mathbb{P}(A|B)$ . La notation  $\mathbb{P}_B(A)$  met en valeur le fait que  $\mathbb{P}_B$  soit une probabilité sur  $(\Omega, \mathcal{A})$ .
- Comme  $(\Omega, \mathcal{A}, \mathbb{P}_B)$  est un espace probabilisé,  $\mathbb{P}_B$  satisfait à toutes les propriétés de la proposition 5.1.
- Si  $\mathbb{P}(A) > 0$  et  $\mathbb{P}(B) > 0$ , on peut réécrire l'équation (7.1) sous la forme :

$$\mathbb{P}(A \cap B) = \mathbb{P}_A(B) \mathbb{P}(A) = \mathbb{P}_B(A) \mathbb{P}(B).$$

- De manière plus générale, si  $(A_k)_{1 \leq k \leq n+1}$  sont des événements qui satisfont à  $\mathbb{P}\left(\bigcap_{k=1}^n A_k\right) > 0$ , alors :

$$\mathbb{P}\left(\bigcap_{k=1}^{n+1} A_k\right) = \mathbb{P}(A_1) \mathbb{P}_{A_1}(A_2) \mathbb{P}_{A_1 \cap A_2}(A_3) \cdots \mathbb{P}_{A_1 \cap \cdots \cap A_n}(A_{n+1}).$$

*Exemple 7.1.* On considère deux lancers successifs d'un même dé. Sachant que le premier jet donne 3, on souhaite calculer la probabilité que la somme soit strictement supérieure à 6.

Supposons que l'on ait choisi l'univers  $\Omega = \{(i, j) : i \in \{1, \dots, 6\}, j \in \{1, \dots, 6\}\}$ , que l'on munit de la tribu  $\mathcal{A} = \mathcal{P}(\Omega)$ . On est alors en situation d'équiprobabilité, et on munit  $\Omega$  de la probabilité uniforme, notée  $\mathbb{P}$ . Ainsi, pour tout événement  $A$  de  $\mathcal{A}$ ,  $\mathbb{P}(A) = \frac{\text{card}(A)}{\text{card}(\Omega)} = \frac{\text{card}(A)}{36}$ .

Soit  $B$  l'événement "le premier jet donne 3";  $B$  est le sous-ensemble  $\{(3, j) : j \in \{1, \dots, 6\}\}$  de  $\mathcal{A}$ , son cardinal est égal à 6, d'où  $\mathbb{P}(B) = \frac{6}{36} = \frac{1}{6} > 0$ . La probabilité  $\mathbb{P}(B)$  étant strictement positive, on peut conditionner par l'événement  $B$ .

Soit  $A$  l'événement "la somme des dés est strictement supérieure à 6";  $A$  est le sous-ensemble  $\{(i, j) \in \Omega : i + j > 6\}$  de  $\mathcal{A}$ , et  $A \cap B = \{(3, 4), (3, 5), (3, 6)\}$ , d'où :  $\mathbb{P}(A \cap B) = \frac{3}{36} = \frac{1}{12}$ . On conclut que :

$$\mathbb{P}_B(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{1}{2}.$$

### 7.1.2 FORMULE DES PROBABILITÉS TOTALES ET FORMULE DE BAYES

**Définition.** Soit  $I$  une partie finie ou dénombrable de  $\mathbb{N}$ . Une famille  $(B_i)_{i \in I}$  d'événements de  $\Omega$  forme un *système complet d'événements* de  $\Omega$ , si

$$\forall i \neq j, B_i \cap B_j = \emptyset, \text{ et } \bigcup_{i \in I} B_i = \Omega.$$

Autrement dit, la famille  $(B_i)_{i \in I}$  est une *partition* de  $\Omega$ .

**Théorème 7.1.** Soit  $(\Omega, \mathcal{A}, \mathbb{P})$  un espace probabilisé.

- **Formule des probabilités totales.** Soit  $(B_i)_{i \in I}$  un système complet d'événements de  $\Omega$ , telle que pour tout  $i \in I$ ,  $\mathbb{P}(B_i) > 0$ , et soit  $A \in \mathcal{A}$ . Alors :

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A \cap B_i) = \sum_{i \in I} \mathbb{P}_{B_i}(A) \mathbb{P}(B_i).$$

Dans le cas particulier où  $I = \{1, \dots, n\}$ , on a :

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A \cap B_i) = \sum_{i=1}^n \mathbb{P}_{B_i}(A) \mathbb{P}(B_i).$$

- **Formule de Bayes.** Soient  $A \in \mathcal{A}$  et  $B \in \mathcal{A}$ , tels que  $0 < \mathbb{P}(A) < 1$  et  $\mathbb{P}(B) > 0$ , alors :

$$\mathbb{P}_B(A) = \frac{\mathbb{P}_A(B) \mathbb{P}(A)}{\mathbb{P}_A(B) \mathbb{P}(A) + \mathbb{P}_{A^c}(B) \mathbb{P}(A^c)}.$$

*Démonstration.* Comme  $(B_i)_{i \in I}$  est une partition de  $\Omega$ , on a :

$$A = A \cap \Omega = A \cap \left( \bigcup_{i \in I} B_i \right) = \bigcup_{i \in I} (A \cap B_i),$$

où les événements  $(A \cap B_i)_{i \in I}$  sont deux-à-deux disjoints. Ainsi, en utilisant la  $\sigma$ -additivité de  $\mathbb{P}$  :

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A \cap B_i) = \sum_{i \in I} \mathbb{P}_{B_i}(A) \mathbb{P}(B_i).$$

Par définition de la probabilité conditionnelle, on a :

$$\mathbb{P}_B(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}_A(B) \mathbb{P}(A)}{\mathbb{P}(B)}.$$

La formule de Bayes est obtenue en appliquant la formule des probabilités totales au dénominateur avec la partition  $\{A, A^c\}$  puisque  $\mathbb{P}(A) \neq 0$  et  $\mathbb{P}(A^c) \neq 0$ . □

*Exemple 7.2.* Un sondage est effectué dans une société comprenant 40% de cadres et 60% d'ouvriers. On sait que 20% des cadres et 10% des ouvriers de cette société savent parler anglais. On interroge une personne "au hasard". Quelle est la probabilité que ce soit :

- un cadre sachant parler anglais ?
- un ouvrier sachant parler anglais ?
- une personne sachant parler anglais ?

L'individu interrogé sait parler anglais. Quelle est la probabilité que ce soit un ouvrier ?

On prend pour univers  $\Omega$  l'ensemble des employés de la société, que l'on munit de la tribu  $\mathcal{A} = \mathcal{P}(\Omega)$ . Étant donné que l'on interroge une personne "au hasard", on munit  $\Omega$  de la probabilité uniforme, notée  $\mathbb{P}$ .

Soit  $C$  l'événement "l'employé est un cadre",  $O$  "l'employé est un ouvrier",  $A$  "l'employé parle anglais". Alors, la donnée du problème nous dit que :

$$\mathbb{P}(C) = \frac{4}{10}, \mathbb{P}(O) = \frac{6}{10}.$$

Comme ces deux probabilités sont strictement positives, on peut conditionner par rapport aux événements  $C$  et  $O$ . D'après la donnée nous savons que :

$$\mathbb{P}_C(A) = \frac{2}{10}, \mathbb{P}_O(A) = \frac{1}{10}.$$

À la première question, on cherche  $\mathbb{P}(C \cap A)$ . D'après la définition des probabilités conditionnelles, on a :

$$\mathbb{P}(C \cap A) = \mathbb{P}_C(A)\mathbb{P}(C) = \frac{2}{10} \frac{4}{10} = 0,08.$$

De manière similaire pour la deuxième question :

$$\mathbb{P}(O \cap A) = \mathbb{P}_O(A)\mathbb{P}(O) = \frac{1}{10} \frac{6}{10} = 0,06.$$

Étant donné que  $\{C, O\}$  forme une partition de  $\Omega$ , d'après la formule des probabilités totales, on a :

$$\mathbb{P}(A) = \mathbb{P}(A \cap C) + \mathbb{P}(A \cap O) = 0,08 + 0,06 = 0,14.$$

Pour répondre à la dernière question, on utilise la formule de Bayes :

$$\mathbb{P}_A(O) = \frac{\mathbb{P}_O(A)\mathbb{P}(O)}{\mathbb{P}(A)} = \frac{1.6}{10.10} \frac{100}{14} = \frac{3}{7}.$$

*Exemple 7.3.* (Paradoxe de Simpson). Cet exemple réel<sup>1</sup> montre un paradoxe surprenant qui s'explique grâce aux probabilités conditionnelles et à la formule des probabilités totales. Il vous convaincra de l'importance de bien comprendre ce concept pour interpréter correctement les résultats d'études statistiques. Il provient d'une étude médicale sur le succès de deux traitements contre les calculs rénaux. Le traitement A a été effectué dans les années 1972-1980, et le traitement B dans les années 1980-1985.

La première table montre le succès global et le nombre de traitements pour chaque méthode.

Succès (taux de succès)	
Traitement A	Traitement B
273/350 (78%)	289/350 (83%)

Cela semble révéler que traitement B, qui est nouveau, est plus efficace. Maintenant, en ajoutant des données concernant la taille des calculs, la comparaison prend une autre tournure :

1. Charig CR, ; Webb DR, ; Payne SR, ; Wickham OE . Comparison of treatment of renal calculi by operative surgery, percutaneous nephrolithotomy, and extracorporeal shock wave lithotripsy. BMJ 1986 ;292 : 879–82. 3

Résultats en fonction de la taille des calculs

petits calculs		grands calculs	
Traitement A	Traitement B	Traitement A	Traitement B
(81/87) 93%	(234/270) 87%	(192/263) 73%	(55/80) 69%

L'information au sujet de la taille des calculs a inversé les conclusions concernant l'efficacité de chaque traitement. Le traitement A est maintenant considéré comme plus efficace dans les deux cas. Le rebroussement de cette inégalité, qui conduit au paradoxe, se produit à cause de deux effets concurrents :

1. la variable supplémentaire (ici la taille) a un impact significatif sur les rapports ;
2. les tailles des groupes qui sont combinés quand la variable supplémentaire est ignorée sont très différentes. (Les groupes utilisés pour le traitement A et B ont la même taille, mais n'ont pas la même répartition de petits et grands calculs).

Vérifions les calculs pour le traitement A. On choisit comme univers  $\Omega$  les 350 patients de l'échantillon, que l'on munit de la tribu  $\mathcal{P}(\Omega)$ . Appelons  $S$  l'événement "le traitement est un succès",  $P$  l'événement "les calculs sont petits". Alors d'après le premier tableau,  $\mathbb{P}(S) = \frac{273}{350}$ , et d'après le deuxième,  $\mathbb{P}(P) = \frac{87}{350}$ ,  $\mathbb{P}(P^c) = \frac{263}{350}$ . Ces deux probabilités étant strictement positives, on peut conditionner par les événements correspondants. D'après le deuxième tableau toujours, on a  $\mathbb{P}_P(S) = \frac{81}{87}$ ,  $\mathbb{P}_{P^c}(S) = \frac{192}{263}$ . Utilisons la formule des probabilités totales pour calculer  $\mathbb{P}(S)$ .

$$\begin{aligned}\mathbb{P}(S) &= \mathbb{P}_P(S)\mathbb{P}(P) + \mathbb{P}_{P^c}(S)\mathbb{P}(P^c) \\ &= \frac{81}{87} \frac{87}{350} + \frac{192}{263} \frac{263}{350} = \frac{273}{350}.\end{aligned}$$

On retrouve bien le résultat du premier tableau. Des calculs similaires permettent de vérifier les résultats pour le traitement B. Ainsi, ces résultats apparemment contradictoires s'expliquent aisément grâce aux probabilités conditionnelles.

## 7.2 INDÉPENDANCE DES ÉVÉNEMENTS

Soit  $(\Omega, \mathcal{A}, \mathbb{P})$  un espace probabilisé.

**Définition.** Deux événements  $A$  et  $B$  de  $\mathcal{A}$  sont dits *indépendants*, si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B).$$

*Exemple 7.4.*

1. Les événements  $\emptyset$  et  $\Omega$  sont indépendants. En effet,

$$\mathbb{P}(\emptyset \cap \Omega) = \mathbb{P}(\emptyset) = 0, \text{ et } \mathbb{P}(\emptyset)\mathbb{P}(\Omega) = 0.1 = 0,$$

d'où,  $\mathbb{P}(\emptyset \cap \Omega) = \mathbb{P}(\emptyset)\mathbb{P}(\Omega)$ .

2. On jette un dé parfaitement équilibré. Soit  $A$  l'événement "obtenir 1,2 ou 3", et  $B$  l'événement "obtenir 1,2,4 ou 5". On choisit comme espace des états,  $\Omega = \{1, \dots, 6\}$ , que l'on munit de la probabilité uniforme. On a alors,

$$\mathbb{P}(A) = \frac{1}{2}, \mathbb{P}(B) = \frac{2}{3}, \mathbb{P}(A \cap B) = \mathbb{P}(\{1, 2\}) = \frac{1}{3}.$$



Ainsi, comme  $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ , on déduit que les événements  $A$  et  $B$  sont indépendants.

*Remarque.*

- L'indépendance n'a rien à voir avec le fait que les événements soient disjoints ou non. Dans l'Exemple 2 ci-dessus, les événements sont indépendants, mais non disjoints ( $A \cap B \neq \emptyset$ ).
- Si  $A$  et  $B$  sont deux événements de probabilité non nulle, alors :

$$A \text{ et } B \text{ sont indépendants} \Leftrightarrow \mathbb{P}(A) = \mathbb{P}_B(A) \Leftrightarrow \mathbb{P}(B) = \mathbb{P}_A(B).$$

Le fait d'avoir une information supplémentaire, à savoir que  $B$  est réalisé, ne modifie pas la probabilité de  $A$  (de même pour  $B$  lorsqu'on sait que  $A$  est réalisé) ce qui justifie la terminologie d'*indépendance*. Ces critères ne sont cependant pas utilisés comme définition car ils nécessitent l'hypothèse supplémentaire,  $\mathbb{P}(A) > 0$  et  $\mathbb{P}(B) > 0$ .

**Proposition 7.1.** *Si les événements  $A$  et  $B$  sont indépendants, il en est de même des événements  $A^c$  et  $B$ ,  $A$  et  $B^c$ ,  $A^c$  et  $B^c$ .*

*Démonstration.* Démontrons que  $A^c$  et  $B$  sont indépendants si  $A$  et  $B$  le sont.

$$\begin{aligned} \mathbb{P}(A^c \cap B) &= \mathbb{P}(B) - \mathbb{P}(A \cap B), \text{ d'après la formule des probabilités totales} \\ &= \mathbb{P}(B)(1 - \mathbb{P}(A)), \text{ car } A \text{ et } B \text{ sont indépendants} \\ &= \mathbb{P}(B)\mathbb{P}(A^c), \text{ donc } A^c \text{ et } B \text{ sont indépendants.} \end{aligned}$$

En remplaçant  $A$  et  $B$  par  $B$  et  $A^c$ , l'implication que l'on vient de prouver entraîne que si  $A^c$  et  $B$  sont indépendants (et donc  $B$  et  $A^c$  indépendants), alors  $B^c$  et  $A^c$  sont indépendants. Et ainsi de suite pour les autres cas.  $\square$

**Définition.**

- Des événements  $A_1, \dots, A_n$  de  $\mathcal{A}$  sont dits *mutuellement indépendants*, si pour tout entier  $1 \leq k \leq n$  et tout  $k$ -uplet d'entiers  $(i_1, \dots, i_k)$ , tels que,  $1 \leq i_1 < \dots < i_k \leq n$ ,

$$\mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) = \mathbb{P}(A_{i_1}) \dots \mathbb{P}(A_{i_k}).$$

- Les événements  $A_1, \dots, A_n$  sont dits *deux-à-deux indépendants*, si pour tout  $i \in \{1, \dots, n\}$ ,  $j \in \{1, \dots, n\}$ , tels que  $i \neq j$ , on a :

$$\mathbb{P}(A_i \cap A_j) = \mathbb{P}(A_i)\mathbb{P}(A_j).$$

# BIBLIOGRAPHIE

- [CDF07] Françoise Couty, Jean Debord, and Daniel Fredon. *Mini-manuel de Probabilités et Statistique*. Dunod, 2007.
- [Chr] Le site Chronomath. <http://serge.mehl.free.fr/>.
- [Del10] Jean-François Delmas. *Introduction au calcul des probabilités et à la statistique*. Les presses de l'ENSTA, [http://cermics.enpc.fr/~delmas/Enseig/ensta\\_cours.pdf](http://cermics.enpc.fr/~delmas/Enseig/ensta_cours.pdf), 2010.
- [Fel68] William Feller. *An introduction to probability theory and its applications. Vol. I*. Third edition. John Wiley & Sons Inc., New York, 1968.
- [Maz05] Fabrice Mazerolle. *Statistique descriptive*. Gualino, Paris, 2005.
- [MPDG97] Sylvie Méléard, Claude Piquet, and Annette Decomps-Guilloux. *Analyse et probabilités*. Problèmes de Mathématiques. Écrit du CAPES 1991–1996. Masson, Paris, 1997. Avec rappels de cours.
- [PR12] Thérèse Phan and Jean-Pierre Rowenczyk. *Exercices et problèmes. Statistique et Probabilités*. Sciences sup. Dunod, 2012.
- [Pri05] Pierre Priouret. Polycopié du cours de Probabilités de L3. [http://www.proba.jussieu.fr/cours/proba\\_L\\_priouret.pdf](http://www.proba.jussieu.fr/cours/proba_L_priouret.pdf), 2004-2005.
- [Pub] Publication 118 de la commission inter-irem lycées techniques. la statistique en quatre séances. carnet de stage. [http://dutarte.perso.neuf.fr/statistique/Brochure\\\_118\\\_Statistique\\\_inferentielle.pdf](http://dutarte.perso.neuf.fr/statistique/Brochure\_118\_Statistique\_inferentielle.pdf).
- [Py94] Bernard Py. *Exercices corrigés de statistique descriptive*. Economica, Paris, 1994.
- [Shi96] A. N. Shiryaev. *Probability*, volume 95 of *Graduate Texts in Mathematics*. Springer-Verlag, New York, second edition, 1996. Translated from the first (1980) Russian edition by R. P. Boas.
- [Vel14] Yvan Velenik. Polycopié du cours de Probabilités et Statistique. <http://www.unige.ch/math/folks/velenik/Cours/2013-2014/ProbaStat/probastat.pdf>, 2014.